ĐỀ 1

Hướng dẫn chung

- Làm bài cá nhân trên VS Code, trên file Jupyter (.ipynb).
- Không được truy cập Internet. Chỉ được đọc các tệp dữ liệu offline trong file Data.zip được cung cấp.
- Không sửa tệp dữ liệu gốc. Tạo thư mục nộp bài **<STT>_HoTen**, gồm mã nguồn và toàn bộ tệp kết quả; mã hóa UTF-8.
- Nộp một tệp nén **<STT>_HoTen.zip**. Chương trình phải chạy lại được từ thư mục nộp bài và sử dụng đường dẫn tương đối, trước khi nộp bài sinh viên phải chạy đủ tất cả các cell trên file Jupyter.

Dữ liệu được cung cấp

Phần	Tệp và thư mục cần dùng
Chương 2	Data/Chuong2/pages/page1.html, page2.html
Chương 3	Data/Chuong3/reviews_raw.csv; emoji_map.csv; tu_dien_chuan_hoa.csv; stopwords.txt

Câu 1. (3.0 điểm) Thu thập và trích xuất dữ liệu web

Cho hai tệp page1.html và page2.html mô phỏng hai trang danh mục laptop. Mỗi sản phẩm nằm trong thẻ article có class product-card. Không tải bất kỳ trang web nào.

a. (1.0 điểm) Đọc tệp Data/Chuong2/pages/page1.html bằng BeautifulSoup với parser html5lib. In ra màn hình đúng tên của 4 sản phẩm trong các thẻ .product-card, mỗi tên trên một dòng.

b. (1.0 điểm) Duyệt cả hai tệp HTML. Bóc tách 4 trường ten_sp, gia_goc, gia_ban, khuyen_mai của tất cả sản phẩm và lưu vào Cau1/san_pham_tho.csv. Tệp phải có header và đúng 8 dòng dữ liệu. Trường khuyen_mai của sản phẩm không có thẻ tương ứng được phép để rỗng ở bước này.

c. (1.0 điểm) Từ san_pham_tho.csv, tạo Cau1/san_pham_sach.csv gồm các cột ten_sp, gia_goc_vnd, gia_ban_vnd, khuyen_mai, ty_le_giam. Giá phải là số nguyên VND; khuyen_mai rỗng thay bằng Không có khuyến mại; ty_le_giam = round((gia_goc_vnd - gia_ban_vnd) / gia_goc_vnd * 100, 2).

Câu 2. (7.0 điểm) Tiền xử lý và khám phá dữ liệu văn bản

Cho file reviews_raw.csv chứa 10 đánh giá khách sạn. Các tệp map và stopwords đi kèm là một phần của dữ liệu đề thi. Lưu các kết quả trong thư mục Cau2.

a. (1.5 điểm) Tạo Cau2/buoc1.csv gồm id và review_buoc1. Thực hiện, theo thứ tự hợp lý: chuyển chữ thường, xóa thẻ HTML, xóa URL, xóa chữ số và chuẩn hóa khoảng trắng. Ở bước này giữ lại emoji, emoticon và dấu câu để xử lý ở ý b.

b. (1.5 điểm) Từ buoc1.csv, sử dụng emoji_map.csv và tu_dien_chuan_hoa.csv để thay thế emoji/emoticon và các từ cần chuẩn hóa. Sau đó xóa dấu câu, chuẩn hóa khoảng trắng và lưu Cau2/buoc2.csv gồm id, review_buoc2. Phải xử lý được viết tắt checkin sau khi bỏ dấu gạch nối.

c. (1.5 điểm) Từ buoc2.csv, tách từ tiếng Việt bằng underthesea.word_tokenize(..., format="text") và loại bỏ các stop word trong stopwords.txt. Lưu Cau2/buoc3.csv gồm id và tokens; các token đã tách từ phải cách nhau bằng khoảng trắng, từ ghép của underthesea được phép giữ dấu gạch dưới.

d. (1.5 điểm) Từ buoc3.csv, thống kê tần suất unigram của toàn bộ token. Lưu Cau2/tan_suat_top10.csv gồm token và tan_suat, sắp xếp giảm dần theo tan_suat, nếu bằng nhau sắp xếp tăng dần theo token. Báo cáo đúng 10 token đầu tiên.

e. (1.0 điểm) Tạo Cau2/bieu_do_top10.png (biểu đồ cột ngang cho 10 token ở ý d) và Cau2/wordcloud.png. Viết Cau2/nhan_xet.txt có ít nhất 2 nhận xét được hỗ trợ bởi kết quả thống kê; nhận xét phải nêu rõ token hoặc cụm nổi bật, không suy diễn thành bài toán phân tích cảm xúc.

Lưu ý: Chỉ chấm điểm các tệp kết quả và mã nguồn có thể chạy lại. Kết quả có khác biệt nhỏ do phiên bản thư viện tách từ vẫn được xem xét nếu xử lý đúng yêu cầu và giải trình rõ ràng.