

BÀI GIẢNG KHAI PHÁ DỮ LIỆU WEB

CHƯƠNG 2.

THU THẬP VÀ TRÍCH XUẤT DỮ LIỆU WEB

NGUYỄN THÀNH THỦY

BỘ MÔN TIN HỌC QUẢN LÝ

TRƯỜNG ĐẠI HỌC KINH TẾ, ĐẠI HỌC ĐÀ NẴNG

THUYNT@DUE.EDU.VN

NỘI DUNG

- ❑ Tổng quan về Web Craping và Web Crawling
- ❑ Các Framework hỗ trợ thu thập dữ liệu
- ❑ Các vấn đề liên quan đến tính pháp lý
- ❑ Cấu trúc và công nghệ xây dựng website
- ❑ Thực hành Web Craping
- ❑ Thực hành Web Crawling




TÀI LIỆU THAM KHẢO

- **[R1] - Python Web Scraping: Hands-on data scraping and crawling using PyQt, Selenium, HTML and Python** (by Katharine Jarmul, Richard Lawson) – 2017, Second Edition; [[Download](#)]
- **[R2] - Practical Web Scraping for Data Science: Best Practices and Examples with Python** (by Seppe vanden Broucke, Bart Baesens) - 2018; [[Download](#)]
- **[R3] - Web Scraping with Python: Collecting More Data from the Modern Web** (by Ryan Mitchell) - 2018, Second Edition; [[Download](#)]
- Mã nguồn: https://github.com/thuy-nguyenthanh/Web_Mining_Class/tree/main/Chapter2

TỔNG QUAN VỀ WEB SCRAPING VÀ WEB CRAWLING

❑ Web Scraping

- Là quá trình thực hiện trích xuất dữ liệu từ các trang web bằng cách thủ công hoặc tự động (chủ yếu), thông qua giao thức HTTP hoặc thông qua trình duyệt web;
- Phần mềm Scraping sẽ thu thập những dữ liệu cần thiết theo yêu cầu của người thiết kế và **không lấy toàn bộ nội dung trang web**, dữ liệu được lưu vào CSDL hoặc các tệp rời rạc, để truy xuất hoặc phân tích sau này.



TỔNG QUAN VỀ WEB SCRAPING VÀ WEB CRAWLING

❑ Web Scraping

Product Name	Price (VND)	Rating	Location
[Mã ELMALL6 giảm 6% đơn 300K] Laptop Huawei Matebo...	11.930.000	★★★★★ Đã bán 363	TP. Hồ Chí Minh
Laptop hp elitebook 840 G3, i5 6200u, ram 8gb, ssd 256gb, 1...	5.999.000	★★★★★ Đã bán 7	TP. Hồ Chí Minh
Máy tính HPI 450G3 Core i5-2.3GHz (6200U) / 8GB / 256...	4.990.000 - 5.900.000	★★★★★ Đã bán 38	Hà Nội
Laptop cũ giá rẻ core i3 core i5 giá tốt nhất	1.500.000 - 6.000.000	★★★★★ Đã bán 76	Hà Nội
Máy HP FOLIO 9470M i5 đẹp	5.800.000	★★★★★ Đã bán 3	Hà Nội
[Mã ELHP12 giảm đến 2TR2] Laptop HP Envy 13-ba1537T...	16.503.000	★★★★★ Đã bán 75	TP. Hồ Chí Minh
[Mã ELHP12 giảm đến 2TR2] Laptop HP Pavilion 15...	10.839.000	★★★★★ Đã bán 26	TP. Hồ Chí Minh
Laptop đồ họa cũ HP 8470p Core i5/Ram 8Gb/Ổ SSD Ch...	3.411.180 - 4.800.000	★★★★★ Đã bán 11	Hà Nội
Laptop kiêm máy tính bảng HP Elite X2 1012G2 i5 7200U/ra...	6.999.000 - 8.199.000	★★★★★ Đã bán 4	Hà Nội
HP 820 G3 DDR4 6300U SANG TRỌNG CẤU HÌNH CAO, GI...	5.380.000 - 6.290.000	★★★★★ Đã bán 23	Hưng Yên


Thu thập thông tin sản phẩm:

- Tên sản phẩm
- Hình ảnh
- Giá bán
- Số lượng đã bán
- Tên địa phương
- ...

TỔNG QUAN VỀ WEB SCRAPING VÀ WEB CRAWLING

❑ Web Scraping

- Kiến trúc hệ thống Web Scraping



Tham khảo thêm: <https://viblo.asia/p/tim-hieu-chung-ve-web-scraping-va-cac-van-de-can-quan-tam-djeZ1yXJZWz>

TỔNG QUAN VỀ WEB SCRAPING VÀ WEB CRAWLING


❑ Web Crawling

- Là quá trình thực hiện trích xuất dữ liệu từ các trang web tương tự kỹ thuật Web Scraping, nhưng phần mềm Web Crawling sẽ duyệt qua tất cả các liên kết (link) có trên trang web và **lấy toàn bộ nội dung trang web**;
- Các liên kết và các từ khóa (keywords) quan trọng trên trang sẽ được đánh chỉ mục (Indexing), dữ liệu sẽ được lưu vào CSDL hoặc các tệp rời rạc;
- Thường sử dụng trên các máy tìm kiếm (Search engine), như Google, Bing, Yahoo,...

TỔNG QUAN VỀ WEB SCRAPING VÀ WEB CRAWLING

❑ Web Crawling


- Mô hình ứng dụng Web Crawling trong các máy tìm kiếm



TỔNG QUAN VỀ WEB SCRAPING VÀ WEB CRAWLING

❑ Web Crawling

- Kiến trúc hệ thống Web Crawling




Tham khảo thêm: <https://spiderum.com/bai-dang/Web-Crawling-va-Web-Scraping-Su-tranh-cai-giua-an-cap-tai-lieu-hay-la-mot-cong-nghe-thu-thap-du-lieu-ruk>

Source: https://www.researchgate.net/publication/307827833/figure/fig1/AS:404469981433865@1473444566671/Abstract-Web-crawler-architecture_W640.jpg

TỔNG QUAN VỀ WEB SCRAPING VÀ WEB CRAWLING


❑ Phân biệt giữa Web Scraping và Web Crawling



CÁC FRAMEWORK HỖ TRỢ THU THẬP DỮ LIỆU

❑ Beautiful Soup (BS4)


- Là một thư viện có thể sử dụng để trích xuất dữ liệu từ các tài liệu HTML và XML;
- Beautiful Soup cho phép di chuyển, tìm kiếm, thay đổi cũng như trích xuất dữ liệu từ cây cú pháp;
- Beautiful Soup là một trong những công cụ phổ biến cho việc thu thập dữ liệu web hiện nay.



CÁC FRAMEWORK HỖ TRỢ THU THẬP DỮ LIỆU

❑ Scrapy Framework


- Scrapy là một framework rất mạnh mẽ trong việc trích xuất dữ liệu;
- Scrapy có kiến trúc sự kiện, cho phép thực hiện các công việc như dọn dẹp, tạo, lưu trữ, làm giàu dữ liệu. Ngoài ra, Scrapy có thể trích xuất dữ liệu từ các API.



CÁC FRAMEWORK HỖ TRỢ THU THẬP DỮ LIỆU

❑ Selenium

- Selenium là công cụ kiểm thử phần mềm và được sử dụng trong thu thập dữ liệu tự động rất phổ biến;
- Selenium script có thể chạy được trên hầu hết các trình duyệt và các hệ điều hành hiện nay. Selenium **đặc biệt hiệu quả khi trang web có sử dụng mã JavaScript.**



CÁC VẤN ĐỀ LIÊN QUAN ĐẾN TÍNH PHÁP LÝ

❑ Tính pháp lý khi thu thập và sử dụng dữ liệu

- Thông tin được đăng tải trên các trang web, thường là những thông tin có bản quyền và quyền phổ biến thông tin của chủ sở hữu;
- Việc thu thập dữ liệu, đặc biệt với quy mô lớn hoặc dữ liệu được sử dụng cho mục đích thương mại, anh/chị cần quan tâm đến tính pháp lý trước khi khai thác;
- **Một số lưu ý quan trọng, trước – trong – và sau khi tiến hành thu thập:**
 - Xin phép bằng văn bản;
 - Kiểm tra các điều khoản sử dụng;
 - Chỉ khai thác thông tin được công khai;
 - Không ảnh hưởng đến hoạt động của hệ thống máy chủ, đường truyền;
 - Bản quyền và sử dụng hợp pháp.

CẤU TRÚC VÀ CÔNG NGHỆ XÂY DỰNG WEBSITE

❑ Tập robots.txt

- Robots.txt là một tệp tin văn bản, nằm tại thư mục gốc của website và cung cấp hướng dẫn cho các công cụ tìm kiếm, thu thập thông tin về các trang có thể thu thập thông tin để lập chỉ mục.

- **Cấu trúc tệp robots.txt**

User-agent: *

Disallow: /wp-admin/

Allow: /wp-admin/admin-ajax.php

Allow: /wp-admin/images/*

Sitemap: <https://yourdomain.com/sitemap.xml>

CẤU TRÚC VÀ CÔNG NGHỆ XÂY DỰNG WEBSITE

❑ Tập robots.txt

■ Cấu trúc tập robots.txt

- **User-agent:** Chỉ định trình thu thập dữ liệu nào được đưa vào các chỉ thị. Sử dụng một dấu * để cho tất cả các trình thu thập thông tin;
- **Disallow:** Chỉ định các bot không được thu thập dữ liệu URL hoặc một phần của trang web;
- **Allow:** chỉ định các trang hoặc thư mục con nào có thể được truy cập;
- **Crawl-delay:** chỉ định thời gian delay giữa các lần thu thập dữ liệu (mili giây);
- **Sitemap:** chỉ định vị trí sơ đồ trang web;

Tham khảo thêm tại đây: https://developers.google.com/search/docs/crawling-indexing/robots/create-robots-txt?hl=vi&ref_topic=6061961&visit_id=638062607108181824-2075086331&rd=1

CẤU TRÚC VÀ CÔNG NGHỆ XÂY DỰNG WEBSITE


❑ Tập robots.txt

Chặn...	Mẫu
Toàn bộ trang web với dấu gạch chéo lên (/):	<code>Disallow: /</code>
Một thư mục và nội dung của nó bằng cách đặt dấu gạch chéo lên sau tên thư mục	<code>Disallow: /sample-directory/</code>
Một trang web bằng cách đưa trang vào sau dấu gạch chéo:	<code>Disallow: /private_file.html</code>
Một hình ảnh cụ thể từ Google Images:	<code>User-agent: Googlebot-Image</code> <code>Disallow: /images/dogs.jpg</code>
Tất cả hình ảnh trên trang web của bạn từ Google Images:	<code>User-agent: Googlebot-Image</code> <code>Disallow: /</code>
Tập thuộc một loại tập cụ thể (ví dụ như .gif):	<code>User-agent: Googlebot</code> <code>Disallow: /*.gif\$</code>
Các trang trên trang web của bạn, nhưng hiển thị quảng cáo AdSense trên các trang đó, không cho phép tất cả các trình thu thập dữ liệu web ngoài Mediapartners-Google. Triển khai này ẩn các trang của bạn từ kết quả tìm kiếm, nhưng trình thu thập dữ liệu web Mediapartners-Google vẫn có thể phân tích trang để quyết định hiển thị quảng cáo nào cho khách truy cập vào trang web của bạn.	<code>User-agent: *</code> <code>Disallow: /</code> <code>User-agent: Mediapartners-Google</code> <code>Allow: /</code>

CẤU TRÚC VÀ CÔNG NGHỆ XÂY DỰNG WEBSITE

❑ Sitemap

- Sitemap là một file liệt kê tất cả liên kết trong một website ở định dạng XML hoặc HTML. Qua đó các công cụ tìm kiếm có thể khám phá và index nội dung trên website một cách dễ dàng.



CẤU TRÚC VÀ CÔNG NGHỆ XÂY DỰNG WEBSITE

❑ Sitemap

■ Ví dụ về Sitemap:

```
▼<urlset xmlns="http://www.sitemaps.org/schemas/sitemap/0.9" xmlns:news="http://www.google.com/schemas/sitemap-news/0.9">
  ▼<url>
    <loc>https://baomoi.com/bao-brazil-dong-doi-khong-nghe-loi-can-hao-cua-neymar/c/44510915.epi</loc>
    ▼<news:news>
      ▼<news:publication>
        <news:name>Báo Mới</news:name>
        <news:language>vi</news:language>
      </news:publication>
      <news:publication_date>2022-12-10T16:30+07:00</news:publication_date>
      <news:title>Báo Brazil: Đồng đội không nghe lời cảnh báo của Neymar</news:title>
      <news:keywords>Neymar,O Globo,Bruno Petkovic,Mislav Orsic,brazil,nghe lời,MARQUINHOS,TUYỂN CROATIA,CBF,RODRYGO,PEN,Liên đoàn bóng đá Brazil,Zlatko Dalic,HIGHLIGHTS,đồng đội,croatia,bất thành,luân lưu,FRED,nhắm</news:keywords>
    </news:news>
  </url>
  ▼<url>
    <loc>https://baomoi.com/them-mot-cau-thu-viet-kieu-co-co-hoi-choi-bong-o-v-league-2023/c/44511926.epi</loc>
    ▼<news:news>
      ▼<news:publication>
        <news:name>Báo Mới</news:name>
        <news:language>vi</news:language>
      </news:publication>
      <news:publication_date>2022-12-10T16:42+07:00</news:publication_date>
      <news:title>Thêm một cầu thủ Việt kiều có cơ hội chơi bóng ở V.League 2023</news:title>
      <news:keywords>V.League 2023,Steven Đặng,Viktor Le,việt kiều,thử việc,Đặng Thanh Hoàng,Việt kiều Na Uy,Người Mỹ gốc Việt,CLB B.Bình Dương,chơi bóng,Bình Định FC,Việt kiều Nga,Alexander Đặng,CLB Bình Dương,Năm 1996,V-League,CLB Nam Định,Đặng Văn Lâm,song sinh,cầu thủ</news:keywords>
    </news:news>
  </url>
```

Nguồn: <https://baomoi.com/sitemaps/sitemap-news.xml>



CẤU TRÚC VÀ CÔNG NGHỆ XÂY DỰNG WEBSITE

❑ Ước tính dung lượng của một website

- Trước khi thu thập dữ liệu từ một website, ta cần ước tính dung lượng website để dự tính được thời gian thực hiện và chuẩn bị tài nguyên để lưu trữ;
- **Cách 1:** sử dụng trình tìm kiếm nâng cao của google
http://www.google.com/advanced_search
- **Cách 2:** tìm kiếm nhanh với cú pháp sau trên công cụ tìm kiếm google
 - site:yourdomain.com
 - site:yourdomain.com/subfolder

CẤU TRÚC VÀ CÔNG NGHỆ XÂY DỰNG WEBSITE

❑ Ước tính dung lượng của một website



CẤU TRÚC VÀ CÔNG NGHỆ XÂY DỰNG WEBSITE

❑ Xác định công nghệ xây dựng một website

- Việc xác định các công nghệ được sử dụng để xây dựng một website, giúp quá trình tổ chức và thu thập dữ liệu được hiệu quả hơn;
- Một số công nghệ phổ biến hiện nay: HTML, PHP, ASP.NET, Javascript, AngularJS, React,...

- Các trang web hỗ trợ xác định công nghệ:

- <https://whatcms.org>
- <https://builtwith.com>
- <https://w3techs.com>
- <https://similartech.com>

What CMS Is This Site Using?
Currently detecting 1326 website powering technologies

Q Detect CMS

✓ Success

JSON

hocructuyen123.net uses

Category	Software	Version
Blog, CMS	WordPress	5.8.6
Programming Language	PHP	5.6.40
Database	MySQL	
Web Server	LiteSpeed	

Social Media

Network	Profile	Url
Facebook	thuynt.it	https://www.facebook.com/thuynt.it

Help us improve these results

hocructuyen123.net

Content Management Systems


Below is a summary of content management systems found on hocructuyen123.net

Checked Pages	CMS
2	WordPress

THỰC HÀNH WEB SCRAPING

❑ Phân tích cấu trúc trang web

- Trang web được cấu thành bởi các thẻ HTML + CSS + JavaScript;
- Để bóc tách được dữ liệu cần thu thập, crawler cần hiểu được các thành phần HTML, CSS và Javascript;



Click phải lên trang,
chọn Inspect



THỰC HÀNH WEB SCRAPING

❑ Phân tích cấu trúc trang web

The screenshot shows a web browser displaying a real estate website. A red box highlights a specific listing for a room for rent. A red arrow points from this listing to the developer tools, which show the HTML structure of the listing. The HTML structure is as follows:

```
<li class="post-item post-id-613470 style-3 clearfix norma
1" style="border-color: #055699;" post-id="613470">
  <script type="application/ld+json">...</script>
  <figure class="post-thumb">...</figure>
  <div class="post-meta">
    <h3 class="post-title">
      <a style="color: #055699;" href="/cho-thue-phong-tro-d
uong-dang-thai-than-pr613470.html"> CHO THUÊ PHÒNG TRỌ
ĐƯỜNG ĐẶNG THÁI THÂN </a> == $0
    </h3>
    <div class="meta-row clearfix">
      <span class="post-price">1.6 triệu/tháng</span>
      <span class="post-acreage">14m²</span>
      <span class="post-location">...</span>
      <time class="post-time" title="Thứ 6, 15:37 23/12/202
2">3 ngày trước</time>
    </div>
```

The developer tools also show the CSS styles for the listing, including the color and text transformation.

Nội dung thẻ HTML, CSS, Javascript,...


Nội dung cần phân tích

THỰC HÀNH WEB SCRAPING

❑ Download trang web với thư viện requests

- Ví dụ 2.1: Sử dụng thư viện requests để lấy nội dung một trang web.


```
import requests
url = 'https://vnexpress.net/arsenal-sap-dung-tuong-wenger-4554241.html'
r = requests.get(url)
print(r.text)
```



THỰC HÀNH WEB SCRAPING

❑ Bóc tách dữ liệu web

- Biểu thức chính quy (Regular expressions)
- Thư viện BeautifulSoup và html5lib



Source: https://res.cloudinary.com/practicaldev/image/fetch/s--0UjFRjoK--/c_imagga_scale,f_auto,fl_progressive,h_420,q_auto,w_1000/https://dev-to-uploads.s3.amazonaws.com/i/zpek00ubevoxvn458b01.png

<https://dev-to-uploads.s3.amazonaws.com/i/zpek00ubevoxvn458b01.png>

THỰC HÀNH WEB SCRAPING

❑ Bóc tách dữ liệu web

■ Biểu thức chính quy (Regex - Regular Expressions)

- **Regex** là một chuỗi ký tự tạo thành một biểu mẫu tìm kiếm (search pattern). Regex được sử dụng để kiểm tra xem một chuỗi có chứa mẫu tìm kiếm được chỉ định hay không;
- **Ví dụ 2.2a:** Trích xuất các chữ số từ một chuỗi ký tự

```
import re
string = 'Lionel Messi was born on 24 June 1987 in Rosario, Santa Fe.In the 2022 FIFA World Cup final on 18 December, Messi made his record 26th World Cup finals appearance at Lusail Stadium'
pattern = '\d+'
result = re.findall(pattern, string)
print(result)
```

Biểu thức chính quy

➔ ['24', '1987', '2022', '18', '26']

Tham khảo thêm:

- <https://docs.python.org/3/howto/regex.html>
- <https://viblo.asia/p/python-regex-Qbq5QMeE5D8>
- <https://laptrinhtudau.com/bieu-thuc-chinh-quy-regex-trong-python/>

THỰC HÀNH WEB SCRAPING

❑ Bóc tách dữ liệu web

■ Biểu thức chính quy (Regex - Regular Expressions)

- Thư viện `re` trong Python hỗ trợ kiểu biểu thức này;
 - Cài đặt thư viện:

```
pip install -U requests
```

- Ví dụ 2.2b: tách tên các món trong chuỗi HTML

```
import re
html = '<ul><li>Coffee</li><li>Tea</li><li>Milk</li></ul>'
L = re.findall("<li>(.*?)</li>", html)

print(L)
```


➔ ['Coffee', 'Tea', 'Milk']

THỰC HÀNH WEB SCRAPING

❑ Bóc tách dữ liệu web

■ Biểu thức chính quy (RegEx - Regular Expressions)

- Ví dụ 2.3: bóc tách dữ liệu trên web **nhatro123.com**. Nội dung cần lấy: **tiêu đề, đơn giá, diện tích, nơi cho thuê, ngày đăng**. Ghi nội dung vào file **NhaTro123.txt**.



The screenshot shows a list of four real estate listings on a website. Each listing includes a small image of the property, a title, a price per month, the area in square meters, the location, and the date it was posted. The listings are as follows:

- Cho thuê nhà đầy đủ nội thất ngay trung tâm thành phố**
3.8 triệu/tháng | 30m² | Quận Hải Châu, Đà Nẵng | 1 ngày trước
Chính chủ cho thuê nhà trọ đầy đủ nội thất- Được trang bị đầy đủ đồ dùng gia đình: máy lạnh, máy giặt, tủ lạnh, nước nóng, tủ âm tường,...
- Nhà một trệt, một lầu 30m2, đầy đủ nội thất ngay Quận Hải Châu**
3.8 triệu/tháng | 30m² | Quận Hải Châu, Đà Nẵng | 1 ngày trước
Chính chủ cho thuê nhà trọ 1 trệt, 1 lầu 30m2 đầy đủ nội thất- Ngay kiệt 4 Duy Tân (bên cạnh siêu thị điện máy Media)- Được trang bị đầy đủ...
- CHO THUÊ PHÒNG TRỌ PHÒNG ĐẸP NHƯ KHÁCH SẠN FULL NỘI THẤT**
2.8 triệu/tháng | 25m² | Quận Sơn Trà, Đà Nẵng | 1 ngày trước
Mình cho thuê phòng ngay Phạm Thiều - Hồ Nghinh - Sơn trà - TP Đà Nẵng
Cách biển vài bước chân 50 phạm Thiều - Sơn Trà- Tp Đà...
- Cho thuê phòng trọ ở trung tâm thành phố**
1.8 triệu/tháng | 17m² | Quận Hải Châu, Đà Nẵng | 2 ngày trước
Cho thuê phòng cho trọ ở q Hải Châu, thoáng mát sạch đẹp, yên tĩnh giá chỉ từ 1,6 tr/th/ng 2tr/th/2ng có Toilet, bếp nấu, có gác lửng. Thang máy, nơi để xe...



Cho thuê nhà đầy đủ nội thất ngay trung tâm thành phố

- 3.8 triệu/tháng
- 30m²
- Quận Hải Châu, Đà Nẵng
- 1 ngày trước

Nhà một trệt, một lầu 30m2, đầy đủ nội thất ngay Quận Hải Châu

- 3.8 triệu/tháng
- 30m²
- Quận Hải Châu, Đà Nẵng
- 1 ngày trước

CHO THUÊ PHÒNG TRỌ PHÒNG ĐẸP NHƯ KHÁCH SẠN FULL NỘI THẤT

- 2.8 triệu/tháng
- 25m²
- Quận Sơn Trà, Đà Nẵng
- 1 ngày trước

Cho thuê phòng trọ ở trung tâm thành phố

- 1.8 triệu/tháng
- 17m²
- Quận Hải Châu, Đà Nẵng
- 2 ngày trước

THỰC HÀNH WEB SCRAPING

❑ Bóc tách dữ liệu web

- **Biểu thức chính quy (Regex - Regular Expressions)**
 - Ví dụ 2.3: bóc tách dữ liệu trên web **nhatro123.com**. Nội dung cần lấy: *tiêu đề, đơn giá, diện tích, nơi cho thuê, ngày đăng*. Ghi nội dung vào file **NhaTro123.txt**.

```
import re
import os
import requests

url="https://phongtro123.com/tinh-thanh/da-nang/"
html = requests.get(url).text

TieuDe=re.findall('<h3 class="post-title"><a.*?>(.*?)</a></h3>', html)
DonGia=re.findall('<span class="post-price">(.*?)</span>', html)
DienTich=re.findall('<span class="post-acreage">(.*?)</span>', html)
DiaChi=re.findall('<span class="post-location"><a.*?>(.*?)</a></span>', html)
NgayDang=re.findall('<time class="post-time" title=.*?>(.*?)</time>', html)
```

THỰC HÀNH WEB SCRAPING

❑ Bóc tách dữ liệu web

■ Biểu thức chính quy (RegEx - Regular Expressions)

- **Bài tập:** Sử dụng RegEx để bóc tách dữ liệu từ <https://philong.com.vn/may-tinh-xach-tay.html>. Nội dung cần lấy: **Tên sản phẩm, Mô tả, Giá bán, Thông tin khuyến mại.**

DANH MỤC SẢN PHẨM

 LOA BOSE GIẢM SỐC 30%

 BUILD PC NHẬN QUÀ KHỦNG 2023

 Chính Sách Bảo Hành Laptop LG Gram

 Mua Laptop Quay 100% Trúng Quà

MÁY TÍNH XÁCH TAY



-13%

i5-11400H | RTX 3050Ti

8GB | 512GB | 16.1" Full HD



Bán chạy

Khuyến mãi

LAPTOP HP VICTUS 16-D0293TX (5Z9R4PA) (INTEL CORE I5-11400H,

- Intel Core i5-11400H (2.7Ghz up to 4.5Ghz, 6 Nhân/12 Luồng, 12MB)
- RAM 8GB (2x4GB) DDR4-2933MHz (2

22.990.000-đ

19.990.000 đ

Khuyến mại:

- Vòng quay may mắn trúng phiếu mua hàng
- Balo hoặc Túi xách laptop Phi Long trị giá :
- Trả góp lãi suất 0% áp dụng cho thẻ tín dụ



-6%

LAPTOP HP PROBOOK 440 G9 (6M0X2PA) (INTEL CORE I5-1235U,

- CPU: Intel Core i5-1235U (1.3Ghz up to 4.4GHz, 10 nhân/ 12 luồng)
- RAM: 8GB (1 x 8GB) DDR4-3200MHz (2



Bán chạy

Khuyến mãi

LAPTOP HP PROBOOK 440 G9 (6M0X2PA) (INTEL CORE I5-1235U,

- CPU: Intel Core i5-1235U (1.3Ghz up to 4.4GHz, 10 nhân/ 12 luồng)
- RAM: 8GB (1 x 8GB) DDR4-3200MHz (2

20.090.000-đ

18.890.000 đ

Khuyến mại:

- Vòng quay may mắn trúng phiếu mua hàng
- Balo hoặc Túi xách laptop Phi Long
- Trả góp lãi suất 0% áp dụng cho thẻ tín dụ



-12%

LAPTOP DELL INSPIRON 16 5620 (P1WKN) (CORE I5-1235U, RAM

- Intel Core i5-1235U (10nhân/ 12luồng; 1.3GHz upto 4.4GHz)
- Ram 8GB DDR4 3200MHz



Bán chạy

Khuyến mãi

LAPTOP DELL INSPIRON 16 5620 (P1WKN) (CORE I5-1235U, RAM

- Intel Core i5-1235U (10nhân/ 12luồng; 1.3GHz upto 4.4GHz)
- Ram 8GB DDR4 3200MHz

22.490.000-đ

19.690.000 đ

Khuyến mại:

- Vòng quay may mắn trúng phiếu mua hàng
- Balo laptop hoặc túi xách Laptop trị giá 35l
- Trả góp lãi suất 0% áp dụng cho thẻ tín dụ



-7%

LAPTOP LENOVO S14 GEN 3 (82TW000DVN) (CORE I3 1215U,

- CPU: Intel Core i3-1215U (10MB Cache, 3.30GHZ up to 4.40GHz, 4 cores, 8 Threads)



Khuyến mãi

LAPTOP LENOVO S14 GEN 3 (82TW000DVN) (CORE I3 1215U,

- CPU: Intel Core i3-1215U (10MB Cache, 3.30GHZ up to 4.40GHz, 4 cores, 8 Threads)

43.990.000-đ

12.990.000 đ

Khuyến mại:

- Vòng quay may mắn trúng phiếu mua hàng
- Balo laptop hoặc túi xách Laptop trị giá 35l
- Trả góp lãi suất 0% áp dụng cho thẻ tín dụ



-12%

LAPTOP MSI GF63 THIN 11UC-443VN (INTEL CORE I5-11400H,

- Intel Core i5-11400H (upto 4.50 GHz, 12MB)
- RAM 8GB DDR4-3200Mhz



Bán chạy

Khuyến mãi

LAPTOP MSI GF63 THIN 11UC-443VN (INTEL CORE I5-11400H,

- Intel Core i5-11400H (upto 4.50 GHz, 12MB)
- RAM 8GB DDR4-3200Mhz

20.990.000-đ

18.490.000 đ

Khuyến mại:

- Vòng quay may mắn trúng phiếu mua hàng
- Balo laptop hoặc túi xách Laptop trị giá 35l
- Trả góp lãi suất 0% áp dụng cho thẻ tín dụ



-19%

LAPTOP LENOVO LEGION 5 15ARH7 (82RD003TVN) (RYZEN 5-

- AMD Ryzen 5-6600H (6 nhân, 12 luồng, 3.3GHz upto 4.5GHz, 16MB cache)
- RAM 16GB (2x 8GB) SO-DIMM DDR5-



Khuyến mãi

LAPTOP LENOVO LEGION 5 15ARH7 (82RD003TVN) (RYZEN 5-

- AMD Ryzen 5-6600H (6 nhân, 12 luồng, 3.3GHz upto 4.5GHz, 16MB cache)
- RAM 16GB (2x 8GB) SO-DIMM DDR5-

42.990.000-đ

34.990.000 đ

Khuyến mại:

- Vòng quay may mắn trúng phiếu mua hàng
- Balo laptop hoặc túi xách Laptop trị giá 35l
- Trả góp lãi suất 0% áp dụng cho thẻ tín dụ

Bài giảng KHAI PHÁ DỮ LIỆU WEB - Nguyễn Thành Thủy, MIS Dept. - DUE

31/52

THỰC HÀNH WEB SCRAPING

❑ Bóc tách dữ liệu web

■ Thư viện BeautifulSoup và html5lib

- Thư viện **html5lib** hỗ trợ hoàn thiện code HTML trước khi đưa vào bóc tách dữ liệu với **Beautiful Soup**
- Cài đặt thư viện

```
pip install beautifulsoup4  
pip install html5lib
```

Tham khảo thêm:

- <https://beautiful-soup-4.readthedocs.io/en/latest/>
- <https://codelearn.io/sharing/web-crawling-voi-beautifulsoup4-python>
- <https://viblo.asia/p/web-crawling-voi-thu-vien-beautifulsoup-1VgZvNGOZAw>
- <https://howkteam.vn/d/thu-vien-beautiful-soup-460>

THỰC HÀNH WEB SCRAPING

❑ Bóc tách dữ liệu web

■ Thư viện BeautifulSoup và html5lib

- Ví dụ 2.4a: sử dụng bộ parser của BeautifulSoup

```
from bs4 import BeautifulSoup

broken_html = '<ul><li>Coffee<li>Tea</li><li>Milk</li></ul>'
soup = BeautifulSoup(broken_html, 'html.parser')

fixed_html = soup.prettify()
print(fixed_html)
```

Input

```
<ul>
  <li>Coffee
  <li>Tea</li>
  <li>Milk</li>
</ul>
```

Lỗi, thiếu thẻ
 đóng

Output

```
<ul>
  <li>Coffee
  <li>Tea</li>
  <li>Milk</li>
</ul>
```

Không khác
phục được lỗi

THỰC HÀNH WEB SCRAPING

❑ Bóc tách dữ liệu web

■ Thư viện BeautifulSoup và html5lib

- Ví dụ 2.4b: sử dụng bộ parser của html5lib

```
from bs4 import BeautifulSoup

broken_html = '<ul><li>Coffee<li>Tea</li><li>Milk</li></ul>'
soup = BeautifulSoup(broken_html, 'html5lib')

fixed_html = soup.prettify()
print(fixed_html)
```

Input

```
<ul>
  <li>Coffee
  <li>Tea</li>
  <li>Milk</li>
</ul>
```

Lỗi, thiếu thẻ
 đóng

Output

```
<ul>
  <li>Coffee</li>
  <li>Tea</li>
  <li>Milk</li>
</ul>
```

Đã tự động
sửa được lỗi

THỰC HÀNH WEB SCRAPING

❑ Bóc tách dữ liệu web

■ Thư viện BeautifulSoup và html5lib

- Ví dụ 2.5a: Bóc tách dữ liệu thông tin trên một trang web. Các thông tin cần lấy: **tiêu đề, đơn giá, diện tích, nơi cho thuê, ngày đăng** → ghi kết quả vào file **NhaTro123.txt**

```
url="https://phongtro123.com/tinh-thanh/da-nang"
html = requests.get(url).text
#Tối ưu hóa code HTML bằng thư viện html5lib
soup = BeautifulSoup(html, 'html5lib')

#Sử dụng thư viện BeautifulSoup để bóc tách dữ liệu
TieuDe = soup.find_all("h3",class_="post-title")
DonGia = soup.find_all("span",class_="post-price")
DienTich = soup.find_all("span",class_="post-acreage")
DiaChi = soup.find_all("span",class_="post-location")
NgayDang = soup.find_all("time",class_="post-time")

str=""
for i in range(len(TieuDe)):
    str+=TieuDe[i].text + "\n"
    str+="- " + DonGia[i].text + "\n"
    str+="- " + DienTich[i].text + "\n"
    str+="- " + DiaChi[i].text + "\n"
    str+="- " + NgayDang[i].text + "\n"
print(str)
```




```
1 CHO THUÊ PHÒNG MỚI ĐẸP 100% CÓ BAN CỐ
2 - 3.5 triệu/tháng
3 - 25m²
4 - Quận Thanh Khê, Đà Nẵng
5 - 7 giờ trước
6 Cho thuê phòng trọ ở trung tâm thành
7 - 1.9 triệu/tháng
8 - 17m²
9 - Quận Hải Châu, Đà Nẵng
10 - 3 giờ trước
11 CHO THUÊ PHÒNG TRỌ ĐƯỜNG ĐẶNG THÁI TH
12 - 1.6 triệu/tháng
13 - 14m²
14 - Quận Ngũ Hành Sơn, Đà Nẵng
15 - 1 ngày trước
16 Cho thuê căn hộ riêng biệt full nội t
17 - 2.9 triệu/tháng
18 - 29m²
19 - Quận Sơn Trà, Đà Nẵng
```

THỰC HÀNH WEB SCRAPING

❑ Bóc tách dữ liệu web

■ Thư viện BeautifulSoup và html5lib

- Ví dụ 2.5c: Bóc tách dữ liệu lấy thông tin dự báo thời tiết từ google theo tên thành phố.



Enter the Name of Any City: Danang
Searching ...

Thời tiết
Thứ Tư 12:00
Nhiều mây
23

THỰC HÀNH WEB SCRAPING

❑ Bóc tách dữ liệu web

■ Thư viện BeautifulSoup và html5lib

- **Bài tập:** Sử dụng BeautifulSoup và html5lib, bóc tách dữ liệu từ: <https://philong.com.vn/may-tinh-xach-tay.html>. Nội dung cần lấy: **Tên sản phẩm, Mô tả, Giá bán, Thông tin khuyến mại.** → ghi kết quả vào file **PhiLong_Laptop.txt**

DANH MỤC SẢN PHẨM

LOA BOSE GIẢM SỐC 30%

BUILD PC NHẬN QUÀ KHỦNG 2023

Chính Sách Bảo Hành Laptop LG Gram

Mua Laptop Quay 100% Trúng Quà

MÁY TÍNH XÁCH TAY



-13%

i5-11400H RTX 3050Ti
8GB 512GB 16.1" Full HD



Bán chạy

Khuyến mãi

LAPTOP HP VICTUS 16-D0293TX (5Z9R4PA) (INTEL CORE I5-11400H,

- Intel Core i5-11400H (2.7Ghz up to 4.5Ghz, 6 Nhân/12 Luồng, 12MB)
- RAM 8GB (2x4GB) DDR4-2933MHz (2

22.990.000 đ

19.990.000 đ

Khuyến mại:

- Vòng quay may mắn trúng phiếu mua hàng
- Balo hoặc Túi xách laptop Phi Long trị giá :**
- Trả góp lãi suất 0% áp dụng cho thẻ tín dụ



-6%

LAPTOP HP PROBOOK 440 G9 (6M0X2PA) (INTEL CORE I5-1235U,

- CPU: Intel Core i5-1235U (1.3Ghz up to 4.4Ghz, 10 nhân/ 12 luồng)
- RAM: 8GB (1 x 8GB) DDR4-3200MHz (2

20.090.000 đ

18.890.000 đ

Khuyến mại:

- Vòng quay may mắn trúng phiếu mua hàng
- Balo hoặc Túi xách laptop Phi Long**
- Trả góp lãi suất 0% áp dụng cho thẻ tín dụ



-12%

LAPTOP DELL INSPIRON 16 5620 (P1WKN) (CORE I5-1235U, RAM

- Intel Core i5-1235U (10 nhân/ 12 luồng; 1.3Ghz upto 4.4Ghz)
- Ram 8GB DDR4 3200MHz

22.490.000 đ

19.690.000 đ

Khuyến mại:

- Vòng quay may mắn trúng phiếu mua hàng
- Balo laptop hoặc túi xách Laptop trị giá 35t
- Trả góp lãi suất 0% áp dụng cho thẻ tín dụ



-7%

LAPTOP LENOVO S14 GEN 3 (82TW000DVN) (CORE I3 1215U,

- CPU: Intel Core i3-1215U (10MB Cache, 3.30GHZ up to 4.40GHZ, 4 cores, 8 Threads)

13.990.000 đ

12.990.000 đ

Khuyến mại:

- Vòng quay may mắn trúng phiếu mua hàng
- Balo laptop hoặc túi xách Laptop trị giá 35t
- Trả góp lãi suất 0% áp dụng cho thẻ tín dụ



-12%

LAPTOP MSI GF63 THIN 11UC-443VN (INTEL CORE I5-11400H,

- Intel Core i5-11400H (upto 4.50 GHz, 12MB)
- RAM 8GB DDR4-3200Mhz

20.990.000 đ

18.490.000 đ

Khuyến mại:

- Vòng quay may mắn trúng phiếu mua hàng
- Balo laptop hoặc túi xách Laptop trị giá 35t
- Trả góp lãi suất 0% áp dụng cho thẻ tín dụ



-19%

LAPTOP LENOVO LEGION 5 15ARH7 (82RD003TVN) (RYZEN 5-

- AMD Ryzen 5-6600H (6 nhân, 12 luồng, 3.3GHZ upto 4.5GHZ, 16MB cache)
- RAM 16GB (2x 8GB) SO-DIMM DDR5-

42.990.000 đ

34.990.000 đ

Khuyến mại:

- Vòng quay may mắn trúng phiếu mua hàng
- Balo laptop hoặc túi xách Laptop trị giá 35t
- Trả góp lãi suất 0% áp dụng cho thẻ tín dụ

Bài giảng KHAI PHÁ DỮ LIỆU WEB - Nguyễn Thành Thủy, MIS Dept. - DUE


37/52

THỰC HÀNH WEB SCRAPING

❑ Bóc tách dữ liệu web

■ Thư viện BeautifulSoup và html5lib

- Ví dụ 2.5b: Bóc tách dữ liệu trên nhiều trang, Nguồn dữ liệu: <https://phongtro123.com/tinh-thanh/da-nang>



Phòng trọ thoáng mát gần khu du lịch XUÂN THIỀU
1.3 triệu/tháng 17m² Quận Liên Chiểu, Đà Nẵng 06/12/2022
PHONGTRO123.com
Phòng trọ thoáng mát, giá cả hợp lí, không chung chủ, taxi đậu tận cửa. Gần KCN Hòa Khánh, đại học bách khoa, đại học sư phạm đn.....Diện tích sử...
Lê Đức cường

Cho thuê căn hộ mini đầy đủ nội thất tại Cẩm Lệ
3 triệu/tháng 20m² Quận Cẩm Lệ, Đà Nẵng 03/12/2022
Cho thuê Căn hộ mini đầy đủ nội thất khép kín. Giò giấc tự do, không chung chủ, khu dân cư an ninh, yên tĩnh. Ngay trung tâm thành phố
Phung viet khuong

Cho thuê trọ công nhân vs người lao động
1.5 triệu/tháng 25m² Quận Liên Chiểu, Đà Nẵng 03/12/2022
Thoáng mát mùa hè, ấm áp mùa đông. Hạ tầng nội thất khép kín, điện nước giá nhà nước, wifi dùng thì chia. Gần chợ, quán ăn, coffee, trường đhsp- đhbk...
Nguyễn duy

1 2 3 4 ... »

Lấy link tự động ở các trang web có phân trang

Cách 1: Sử dụng Biểu thức chính quy để quét link

Cách 2: Dựa trên quy tắc cấu trúc url để tạo link

THỰC HÀNH WEB SCRAPING

❑ Bóc tách dữ liệu web

■ Thư viện BeautifulSoup và html5lib

- **Bài tập:** xây dựng tập hyperlink để chuẩn bị cho thu thập dữ liệu, Nguồn dữ liệu:

<https://truyenfull.vn/the-loai/kiem-hiep>

- **Cách 1:** Sử dụng Biểu thức chính quy để quét link
- **Cách 2:** Dựa trên quy tắc cấu trúc url để tạo link



Mộng Giang Hồ
✍ Mạc Phong Trần

Chương 83




Tiên Thiên Đại Giới
✍ Thế Nhân

Chương 55

1 2 3 4 6 11 > Cuối » Chọn trang ▲

THỰC HÀNH WEB CRAWLING

❑ Quy trình Crawling một website



Source: <https://limeproxies.netlify.app/blog/crawling-vs-scraping>

THỰC HÀNH WEB CRAWLING

❑ Crawling nội dung một trang web

```
import requests
from bs4 import BeautifulSoup
url="https://vnexpress.net/seoul-e-land-vs-cheongju-4576178.html"

# Lấy mã nguồn của trang
html = requests.get(url).text
print(html)

# Lấy phần nội dung văn bản của trang
texts = BeautifulSoup(html, 'html.parser').get_text()
print(texts)
```

THỰC HÀNH WEB CRAWLING

❑ Crawling nội dung một trang web

- Một số trang chặn không cho thu thập dữ liệu

- Ví dụ:

- <https://laodong.vn/giao-thong/cong-an-ha-noi-them-giai-phap-manh-tai-xe-ma-men-kho-ne-chot-1152791.ldo>

THỰC HÀNH WEB CRAWLING

❑ Crawling toàn bộ nội dung website lấy link từ file .rss

- Ví dụ 2.6: Lấy link từ file .rss, lưu mã nguồn HTML của trang ở dạng file .html, tên file là đường link.
- Nguồn dữ liệu: <https://vnexpress.net/rss/the-thao.rss>

```
▼<rss xmlns:slash="http://purl.org/rss/1.0/modules/slash/" version="2.0">
```

```
▼<channel>
```

```
<title>Thể thao - VnExpress RSS</title>
```

```
<description>VnExpress RSS</description>
```

```
▼<image>
```

```
<url>https://s.vnecdn.net/vnexp
```

```
<title>Tin nhanh VnExpress - Đ
```

```
<link>https://vnexpress.net</li
```

```
</image>
```

```
<pubDate>Fri, 30 Dec 2022 15:07:17 +0700</pubDate>
```

```
<generator>VnExpress</generator>
```

```
<link>https://vnexpress.net/rss/the-thao.rss</link>
```

```
▼<item>
```

```
<title>15 tuyệt kỹ của Pele được nhiều h
```

```
▼<description>
```

```
<![CDATA[ <a href="https://vnexpress.net/thethao.vnecdn.net/2022/12/30/capa-1163Pele qua đời ngày 29/12, báo Brazil Glo]]>
```

```
** Now visiting: https://vnexpress.net/psg-mat-ney-mar-o-tran-luot-ve-gap-bayern-4572956.html
Saving file,...
** Now visiting: https://vnexpress.net/ba-guong-mat-moi-tranh-giai-dong-doi-vm-hanoi-midnight-2023-4565172.html
Saving file,...
** Now visiting: https://vnexpress.net/khoi-tranh-vga-tour-2023-4573005.html
Saving file,...
** Now visiting: https://vnexpress.net/huynh-nhu-loi-choi-cua-viet-nam-va-bo-dao-nha-khong-khac-nhieu-4573030.html
Saving file,...
** Now visiting: https://vnexpress.net/klopp-chua-nguoi-am-anh-thua-real-4572957.html
Saving file,...
** Now visiting: https://vnexpress.net/dani-alves-lai-thay-doi-loi-khai-4572962.html
```

```
https://vnexpress.net/alcaraz-doat-danh-hieu-dau-tien-trong-nam-2023-4572768.html.html
```

```
https://vnexpress.net/ancelotti-real-khong-the-da-voi-liverpool-nhu-chung-ket-mua-truoc-4572062.html.html
```

```
https://vnexpress.net/ancelotti-real-nguoc-dong-con-hay-hon-mong-uoc-cua-toi-4573468.html.html
```

```
https://vnexpress.net/ba-guong-mat-moi-tranh-giai-dong-doi-vm-hanoi-midnight-2023-4565172.html.html
```

```
https://vnexpress.net/ba-ly-do-cac-gia-dinh-nen-tham-gia-giai-chay-happy-run-4573212.html.html
```

```
https://vnexpress.net/bao-phap-che-quang-hai-thieu-chinh-xac-4573101.html.html
```

Source Code: https://github.com/thuy-nguyenthanh/Web_Mining_Class/blob/main/Chapter2/Exam26.py

THỰC HÀNH WEB CRAWLING

❑ Crawling toàn bộ nội dung website lấy link từ file .rss

- Ví dụ 2.7: Lấy link từ file .rss, bóc tách nội dung văn bản của trang lưu ở dạng file .txt, tên file là đường link.
- Nguồn dữ liệu: <https://vnexpress.net/rss/the-thao.rss>

```
▼<rss xmlns:slash="http://purl.org/rss/1.0/modules/slash/" version="2.0">
```

```
▼<channel>
```

```
<title>Thể thao - VnExpress RSS
```

```
<description>VnExpress RSS</des
```

```
▼<image>
```

```
<url>https://s.vnecdn.net/vne
```

```
<title>Tin nhanh VnExpress -
```

```
<link>https://vnexpress.net</
```

```
</image>
```

```
<pubDate>Fri, 30 Dec 2022 15:07
```

```
<generator>VnExpress</generator>
```

```
<link>https://vnexpress.net/rss/the-thao.rss</link>
```

```
▼<item>
```

```
<title>15 tuyệt kỹ của Pele được nhiều hậu
```

```
▼<description>
```

```
<![CDATA[ <a href="https://vnexpress.net/thethao.vnecdn.net/2022/12/30/capa-1163-1Pele qua đời ngày 29/12, báo Brazil Glob
```

```
Saving file,...
** Now visiting: https://vnexpress.net/khoi-tranh-vga-tour-2023-4573005.html
Saving file,...
** Now visiting: https://vnexpress.net/huynh-nhu-loi-choi-cua-viet-nam-va-bo-dao-nha-khong-khac-nhieu-4573030.html
Saving file,...
** Now visiting: https://vnexpress.net/klopp-chua-nguoi-am-anh-thua-real-4572957.html
Saving file,...
** Now visiting: https://vnexpress.net/dani-alves-lai-thay-doi-loi-khai-4572962.html
Saving file,...
** Now visiting: https://vnexpress.net/costacurta-napoli-manh-hon-man-city-4572964.html
Saving file,...
** Now visiting: https://vnexpress.net/ancelotti-real-khong-the-da-voi-liverpool-nhu-chung-ket-mua-truoc-4572062.html
Saving file,...
** Now visiting: https://vnexpress.net/vieira-chuc-vo-dich-se-thuoc-ve-arsenal-4572963.html
```

```
httpsvnexpress.netalcaraz-doat-danh-hieu-dau-tien-trong-nam-2023-4572768.html.txt
httpsvnexpress.netancelotti-real-khong-the-da-voi-liverpool-nhu-chung-ket-mua-truoc-4572062.html.txt
httpsvnexpress.netancelotti-real-nguoc-dong-con-hay-hon-mong-uoc-cua-toi-4573468.html.txt
httpsvnexpress.netba-guong-mat-moi-tranh-giai-dong-doi-vm-hanoi-midnight-2023-4565172.html.txt
httpsvnexpress.netba-ly-do-cac-gia-dinh-nen-tham-gia-giai-chay-happy-run-4573212.html.txt
```

Source Code: https://github.com/thuy-nguyenthanh/Web_Mining_Class/blob/main/Chapter2/Exam26.py

THỰC HÀNH WEB CRAWLING

❑ Crawling toàn bộ nội dung trang web từ file .rss

- **Bài tập:** Lấy link từ file .rss, nguồn dữ liệu:

A. Báo Thanh Niên: <https://thanhnien.vn/rss/kinh-te.rss>

B. Báo Tuổi Trẻ: <https://tuoitre.vn/rss/kinh-doanh.rss>

C. Báo Tinh Tế: <https://tinhte.vn/rss/>

D. Báo Trải Nghiệm Số: <https://trainghiemso.vn/feed/>

E. Báo VTC: <https://vtcnews.vn/rss/suc-khoe.rss>

F. Báo Dân Việt: <https://danviet.vn/rss/doi-song-1190.rss>

G. Báo CafeBiz: <https://cafebiz.vn/rss/xa-hoi.rss>

Câu 1. Lưu mã nguồn HTML của trang ở dạng file .html, tên file là đường link.


Câu 2. Bóc tách nội dung văn bản của trang lưu ở dạng file .txt, tên file là đường link.

Source Code: https://github.com/thuy-nguyenthanh/Web_Mining_Class/blob/main/Chapter2/Exam27.py

THỰC HÀNH WEB CRAWLING

❑ Crawling nội dung website từ hyperlink trên website

- Ví dụ 2.8: Tự động quét hyperlink trên website, lấy toàn bộ thẻ HTML lưu ở dạng file .html, tên file là đường link của trang web. Nguồn dữ liệu: <https://vnexpress.net/>



The screenshot illustrates a web crawling process on the website <https://vnexpress.net/>. The browser interface shows the homepage with a large photo of a parliament session. A terminal window is overlaid, displaying the crawler's progress:

```
** Now visiting: https://vnexpress.net/
Saving file,...
+ 78 new link(s) found
+ 1 link(s) seen/ 78 link(s) need to do.
Enter to continues, ...

** Now visiting: https://vnexpress.net/chay-song-bac-o-campuchia-11-nguoi-thiet-m
Saving file,...
+ 1 new link(s) found
+ 2 link(s) seen/ 78 link(s) need to do.
Enter to continues, ...

** Now visiting: https://vnexpress.net/chu-de/thai-lan-699
Saving file,...
+ 45 new link(s) found
+ 3 link(s) seen/ 122 link(s) need to do.
Enter to continues, ...
```

Below the terminal, a list of generated HTML files is shown:

- <https://vnexpress.net/html>
- https://vnexpress.net/chay-song-bac-o-campuchia-11-nguoi-thiet-mang-4554003.htmlbox_comment_vne.html
- <https://vnexpress.net/chu-de/thai-lan-699.html>
- <https://vnexpress.net/chu-de/thai-lan-699-p4.html>
- <https://vnexpress.net/chu-de/thai-lan-699-p5.html>
- <https://vnexpress.net/chu-de/thai-lan-699-p6.html>
- <https://vnexpress.net/chu-de/thai-lan-699-p7.html>
- <https://vnexpress.net/chu-de/thai-lan-699-p8.html>

MỘT SỐ NGUỒN DỮ LIỆU VĂN BẢN TIẾNG VIỆT

- Large-scale Vietnamese News Corpus ([Link](#))
- Binhvq News Corpus ([Link](#))
- ViWiKi ([Link](#))

ĐỌC THÊM VỀ NHÀ

- Chapter 8: Scrapy (R1 - P.154)
- Chapter 5. Scrapy (R2 - P.92)
- Chapter 6. Storing Data (R2- P.115)
- Chapter 6: Interacting with Forms (R1 – P119)
- Chapter 10. Crawling Through Forms and Logins (R2- P.195)
- Chapter 4: Concurrent Downloading (R1 – P.81)
- Chapter 16. Web Crawling in Parallel (R2- P.302)

BÀI TẬP ÔN TẬP - THỰC HÀNH NHÓM

Tham khảo tài liệu [R3] để thực hiện các bài tập sau:

Bài 1. Scraping Hacker News (P.199)

Bài 2. Quotes to Scrape (P.202)

Bài 3. Books to Scrape (P.206)

Bài 4. Scraping and Visualizing IMDB Ratings (P.220)

Bài 5. Sentiment Analysis of Scraped Amazon Reviews (P.241)

Bài 6. Scraping and Analyzing News Articles (P.252)

FINAL LAB - THỰC HÀNH NHÓM

Bài tập theo nhóm, thực hiện các yêu cầu sau:

Code Python được thực hiện trên Jupyter NoteBook.

Nguồn dữ liệu: <https://vov.gov.vn/Rss/RssChuyende?pageSize=&chuyendeld=14>

Câu 1. Xây dựng tập hyperlink chuyển trang, lưu vào file Cau1.txt.



Câu 2. Xây dựng tập hyperlink của các bài báo trên trang, lưu vào file Cau2.txt;



Hội Báo toàn quốc 2023: “Đoàn kết, Chuyên nghiệp, Văn hóa, Sáng tạo”

4 giờ trước | VOV5

Hội Báo toàn quốc 2023: “Đoàn kết, Chuyên nghiệp, Văn hóa, Sáng tạo”

FINAL LAB - THỰC HÀNH NHÓM

Bài tập theo nhóm, thực hiện các yêu cầu sau:

Nguồn dữ liệu: <https://vov.gov.vn/Rss/RssChuyende?pageSize=&chuyendeld=14>

Câu 3. Bóc tách các nội dung, gồm: Tiêu đề bài báo, Tóm tin, Ngày giờ đăng bài, Nguồn tin. Lưu vào 1 file đặt tên Cau3.txt.



Hội Báo toàn quốc 2023: "Đoàn kết, Chuyên nghiệp, Văn hóa, Sáng tạo"

4 giờ trước | VOV5

Hội Báo toàn quốc 2023: "Đoàn kết, Chuyên nghiệp, Văn hóa, Sáng tạo"

Câu 4. Lưu toàn bộ mã nguồn HTML của trang vào file .html, tên file là tên đường link.

Câu 5. Lưu toàn bộ nội dung văn bản của trang vào file .txt, tên file là đường link. Chỉ bóc tách phần tiêu đề và nội dung bài báo.

FINAL LAB - THỰC HÀNH NHÓM

Yêu cầu: Tạo thư mục có tên **<STT1>_<STT2>_<STT3>**, lưu toàn bộ bài làm vào thư mục này. Sau khi hoàn thành, SV zip/rar thư mục STT và nộp file này lên elearning.

Vì dụ:

\5_15_20

\Cau1

\Cau1.ipynb

\Cau1.txt

\Cau2

\Cau2.ipynb

\Cau2.txt

\Cau3

\Cau3.ipynb

\Cau3.txt

\Cau4

\Cau4.ipynb

\Data (các file .html lưu vào thư mục này)

\Cau5

\Cau5.ipynb

\Data (các file .txt lưu vào thư mục này)