

BÀI GIẢNG
KHAI PHÁ DỮ LIỆU WEB
CHƯƠNG 5.
PHÂN CỤM VĂN BẢN

NGUYỄN THÀNH THỦY

BỘ MÔN TIN HỌC QUẢN LÝ

TRƯỜNG ĐẠI HỌC KINH TẾ, ĐẠI HỌC ĐÀ NẴNG

THUYNT@DUE.EDU.VN


NỘI DUNG

- ❑ Tổng quan về phân cụm văn bản
- ❑ Độ đo tương đồng văn bản
- ❑ Phân tích độ tương đồng của văn bản
- ❑ Các thuật toán phân cụm văn bản
- ❑ Phân cụm văn bản với thuật toán K-Means

TỔNG QUAN VỀ PHÂN CỤM VĂN BẢN

❑ Phân cụm văn bản

- **Phân cụm văn bản** (Text Clustering) là một kỹ thuật học không giám sát (unsupervised learning), nhằm thực hiện **nhóm các văn bản có nội dung tương tự lại với nhau trong các cụm khác nhau**;
- Nhằm **tìm ra các nhóm văn bản có liên quan đến nhau** để giúp cho việc quản lý và truy xuất các văn bản trở nên dễ dàng hơn;
- Các phương pháp phân cụm văn bản thường sử dụng các kỹ thuật như **TF-IDF, Vector Space Model, Hierarchical Clustering, K-means, DBSCAN,...**



Source: https://static.wixstatic.com/media/25cc7a_25163acc715140aea64cb646b0f7959e~mv2.png/v1/fit/w_800%2Ch_321%2Cal_c%2Cq_80,enc_auto/file.jpg

TỔNG QUAN VỀ PHÂN CỤM VĂN BẢN


□ Các ứng dụng của phân cụm văn bản

- **Phân cụm các bài báo:** nhóm các bài báo có cùng chủ đề lại với nhau;
- **Phân cụm văn bản khảo sát:** phân loại các câu trả lời trong khảo sát theo các chủ đề, như ý kiến về sản phẩm, chất lượng dịch vụ,...;
- **Phân cụm các email:** phân nhóm các email thành các cụm khác nhau, như phân loại email quảng cáo, email công việc, email cá nhân,...;
- **Phân cụm tài liệu luật:** phân loại các tài liệu luật dựa trên các lĩnh vực khác nhau, như luật sở hữu trí tuệ, luật thương mại,...;
- **Phân cụm các đoạn văn trong tài liệu dài:** phân chia các đoạn văn trong tài liệu dài thành các nhóm khác nhau để phân tích và hiểu nội dung tài liệu;
- **Phân cụm bình luận và đánh giá sản phẩm:** phân nhóm các bình luận và đánh giá của khách hàng về sản phẩm dựa trên nội dung;
- **Phân cụm các trang web:** nhóm các trang web có nội dung tương tự liên quan đến chủ đề;

TỔNG QUAN VỀ PHÂN CỤM VĂN BẢN

❑ Tương đồng văn bản

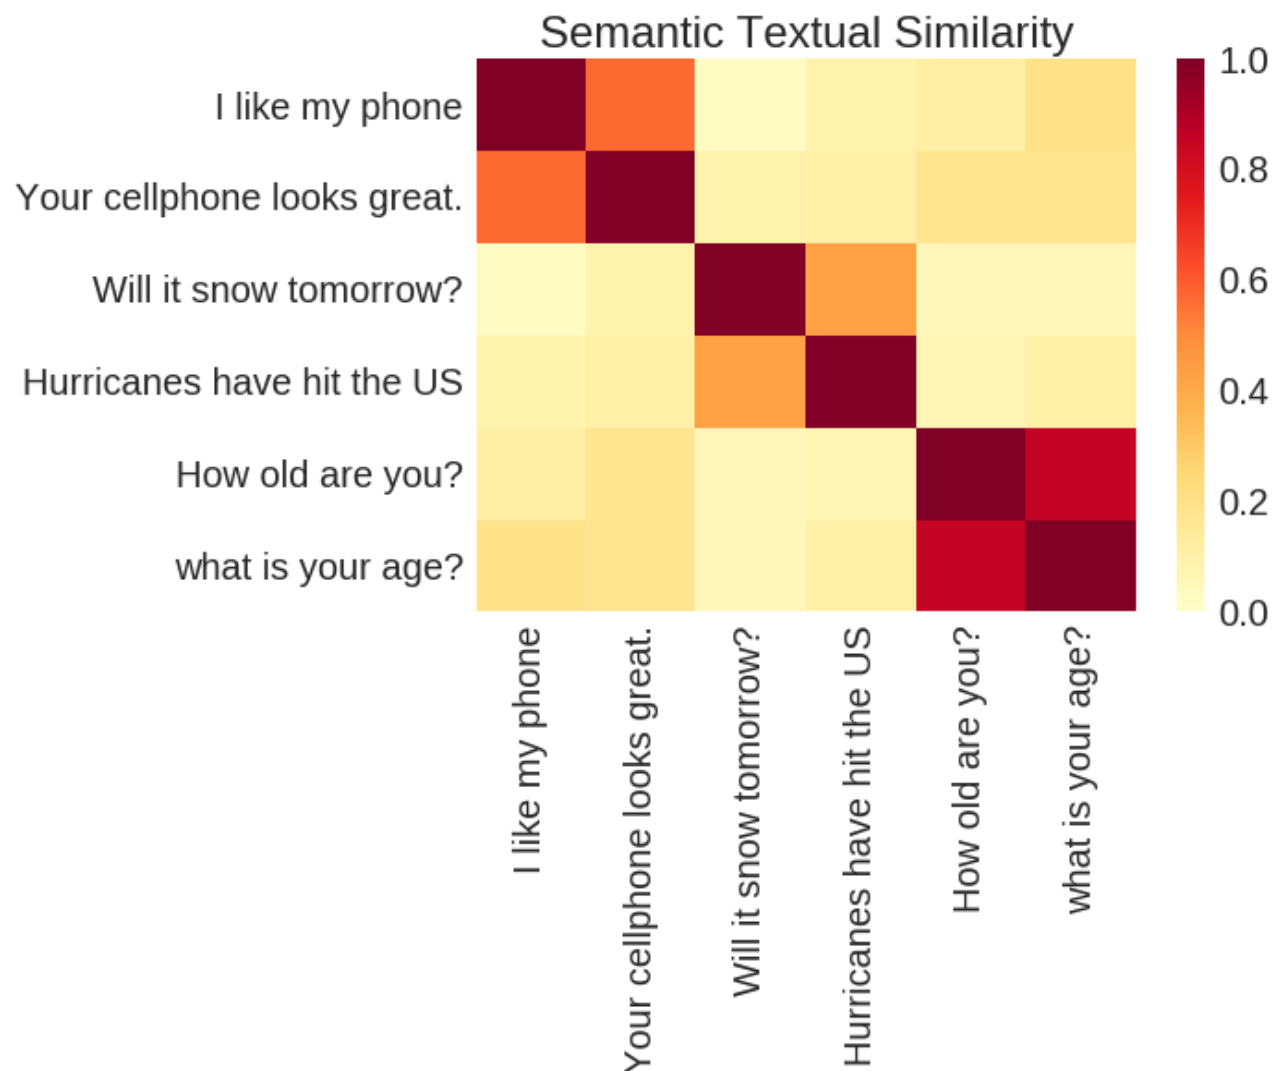
- **Tương đồng văn bản** (Text Similarity/ Tương tự văn bản), là mức độ giống nhau về nội dung giữa hai hay nhiều văn bản;
- Mức độ tương đồng được tính dựa trên một số độ đo, sẽ đưa ra một giá trị số học để biểu thị mức độ tương đồng giữa các văn bản;



Source: https://miro.medium.com/v2/resize:fit:828/format:webp/1*b_yOLau83bYR7BYDNwKzfw.png

TỔNG QUAN VỀ PHÂN CỤM VĂN BẢN

❑ Tương đồng văn bản



Source: <https://2.bp.blogspot.com/-9Qk1fubLpzg/Wv2QGgKVVMl/AAAAAAAAACvs/Gm-XF3prXVIIvalkrTmkclcYz-4qSxLKwCLcBGAs/s1600/image2.png>

TỔNG QUAN VỀ PHÂN CỤM VĂN BẢN

❑ Các hình thức phân cụm văn bản

- Dựa trên sự Bằng phẳng hoặc Phân cấp
- Dựa trên sự Chồng chéo
- Dựa trên Mục tiêu


TỔNG QUAN VỀ PHÂN CỤM VĂN BẢN

❑ Các hình thức phân cụm văn bản

■ Dựa trên sự Bằng phẳng hoặc Phân cấp

- Phân cụm phẳng (Flat Clustering)

- Các đối tượng được phân loại thành các nhóm dựa trên sự tương đồng giữa chúng;
- Kỹ thuật này không thể phân tách được các nhóm con trong mỗi nhóm lớn hơn.



TỔNG QUAN VỀ PHÂN CỤM VĂN BẢN

❑ Các hình thức phân cụm văn bản

■ Dựa trên sự Bằng phẳng hoặc Phân cấp


- Phân cụm theo thứ bậc (Hierarchical Clustering)

- Các đối tượng được phân loại vào các nhóm dựa trên sự tương đồng, sau đó các nhóm này được kết hợp để tạo thành các nhóm lớn hơn.
- Quá trình này được lặp lại cho đến khi tất cả các đối tượng được phân loại vào một nhóm duy nhất;
- Kỹ thuật này phân tách được các nhóm con trong mỗi nhóm lớn hơn.

TỔNG QUAN VỀ PHÂN CỤM VĂN BẢN

□ Các hình thức phân cụm văn bản

- Dựa trên sự Bằng phẳng hoặc Phân cấp
 - Phân cụm theo thứ bậc (Hierarchical Clustering)



TỔNG QUAN VỀ PHÂN CỤM VĂN BẢN

❑ Các hình thức phân cụm văn bản


■ Dựa trên sự Chồng chéo

- Phân cụm cứng (Hard Clustering)

- Mỗi đối tượng dữ liệu chỉ được phân vào **một nhóm cụ thể**.
- Thường được sử dụng khi ta **biết trước số lượng nhóm cần phân chia** và muốn phân chia các đối tượng vào các nhóm cụ thể.

- Phân cụm mềm (Soft Clustering)

- Mỗi đối tượng dữ liệu có thể thuộc vào **nhiều nhóm khác nhau**;
- Thường được sử dụng khi ta **không biết trước số lượng nhóm cần phân chia** và muốn xác định mức độ tương đồng giữa các đối tượng dữ liệu.



TỔNG QUAN VỀ PHÂN CỤM VĂN BẢN

□ Các hình thức phân cụm văn bản

■ Dựa trên sự Chồng chéo

- Ví dụ:

- **Phân cụm cứng** là khi phân loại các từ vào các nhóm khác nhau dựa trên từ loại của chúng, ví dụ như phân loại các từ thành danh từ, động từ, tính từ, trạng từ;
- **Phân cụm mềm** là khi phân loại các văn bản thành các chủ đề khác nhau, trong đó văn bản có thể thuộc vào nhiều chủ đề với một mức độ tương đồng khác nhau.

TỔNG QUAN VỀ PHÂN CỤM VĂN BẢN

□ Các hình thức phân cụm văn bản

■ Dựa trên Mục tiêu

- Phân cụm đơn sắc (Monothetic Clustering)

- Các đối tượng được phân loại **dựa trên một thuộc tính riêng biệt**;
- Ví dụ, khi phân loại các từ thành các nhóm dựa trên độ dài của chúng, các từ có độ dài từ 1 đến 3 ký tự được phân vào một nhóm, từ 4 đến 6 ký tự được phân vào một nhóm khác, và từ 7 ký tự trở lên được phân vào một nhóm khác.

- Phân cụm đa sắc (Polythetic Clustering)

- Các đối tượng được phân loại **dựa trên nhiều thuộc tính khác nhau**;
- Ví dụ, khi phân loại các từ thành các nhóm dựa trên từ loại và chủ ngữ của chúng, các danh từ với chủ ngữ là "người" được phân vào một nhóm, các động từ với chủ ngữ là "người" được phân vào một nhóm khác, và các tính từ với chủ ngữ là "người" được phân vào một nhóm khác.

TỔNG QUAN VỀ PHÂN CỤM VĂN BẢN


❑ Các cấp độ phân cụm văn bản

- Phân cụm cấp độ tài liệu (Document-level Clustering);
- Phân cụm cấp độ câu (Sentence-level Clustering);
- Phân cụm cấp độ từ (Word-level Clustering).

TỔNG QUAN VỀ PHÂN CỤM VĂN BẢN

❑ Các bước để thực hiện phân cụm văn bản

- **Bước 1:** Chuẩn bị dữ liệu;
- **Bước 2:** Tiền xử lý dữ liệu;
- **Bước 3:** Xây dựng vector đặc trưng;
- **Bước 4:** Lựa chọn thuật toán phân cụm phù hợp;
- **Bước 5:** Đánh giá và tinh chỉnh mô hình;
- **Bước 6:** Sử dụng kết quả phân cụm;



Sinh viên đọc thêm: <https://www.mdpi.com/2076-3417/13/1/342>

Bài giảng KHAI PHÁ DỮ LIỆU WEB - Nguyễn Thành Thủy, MIS Dept. - DUE

Source: https://www.mdpi.com/applsci/applsci-13-00342/article_deploy/html/images/applsci-13-00342-g001-550.jpg

ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

□ Khái niệm

- Phát biểu bài toán tính độ tương đồng văn bản như sau:
 - Xét một tài liệu D gồm có n câu: $D = s_1, s_2, \dots, s_n$
 - Mục tiêu của bài toán là tìm ra một giá trị của hàm $S(s_i, s_j)$, và $i, j = 1, \dots, n$
 - Hàm $S(s_i, s_j)$ được gọi là **độ đo tương đồng giữa 2 văn bản s_i và s_j** . Giá trị càng cao thì sự giống nhau về nghĩa của 2 văn bản càng nhiều.
- Ví dụ, xét 2 câu “Tôi là nam” và “Tôi là nữ”,
 - Bằng trực quan có thể thấy rằng 2 câu trên có sự tương đồng khá cao;
 - Trên thực tế, khó có thể lấy một giá trị chính xác bởi vì ngữ nghĩa chỉ được hiểu đầy đủ trong một ngữ cảnh cụ thể.

Source: “Nghiên cứu phương pháp so sánh độ tương đồng văn bản bằng độ đo cosine”, Phạm Thị Hải Vân, Phạm Hữu Lợi, 2016.

Link: <https://drive.google.com/file/d/1-uYgyruA2xBXeNbQXhvDsuMrgprspaTW/view?usp=sharing>


ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

- ❑ Các độ đo tương đồng văn bản phổ biến
 - Cosine similarity;
 - Jaccard similarity;
 - Euclidean distance;
 - Manhattan distance;
 - Edit distance;

ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

❑ Cosine similarity

- **Cosine similarity** là phương pháp đo lường mức độ giống nhau giữa hai văn bản, bằng cách tính cosine của góc giữa các **vector biểu diễn** của chúng.



Source: <https://www.oreilly.com/api/v2/epubs/9781788295758/files/assets/2b4a7a82-ad4c-4b2a-b808-e423a334de6f.png>

ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

□ Cosine similarity

- Các bước thực hiện:
 - **Bước 1:** Biểu diễn văn bản dưới dạng vector đặc trưng: Bag-of-words, TF-IDF, Word embedding hoặc Word2Vec;
 - **Bước 2:** Tính toán cosine similarity bằng cách tính cosine của góc giữa hai vector đặc trưng của hai văn bản đó;
 - **Bước 3:** Đánh giá mức độ tương đồng dựa trên giá trị cosine similarity, với giá trị từ 0 (không tương đồng) đến 1 (hoàn toàn tương đồng).

ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

□ Cosine similarity

- Ví dụ, cho tập D gồm 2 câu văn bản:
doc_1 = "Data is the oil of the digital economy"
doc_2 = "Data is a new oil"

#**Bước 1:** Xây dựng vector đặc trưng Word2Vec

doc_1_vector = [1, 1, 1, 1, 0, 1, 1, 2]

doc_2_vector = [1, 0, 0, 1, 1, 0, 1, 0]

	data	digital	economy	is	new	of	oil	the
doc_1	1	1	1	1	0	1	1	2
doc_2	1	0	0	1	1	0	1	0

ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

□ Cosine similarity

- Ví dụ, cho tập D gồm 2 câu văn bản:

#**Bước 2**: Tính cosine của góc giữa hai vector đặc trưng

$$\text{similarity} = \cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}},$$

ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

□ Cosine similarity

- Ví dụ, cho tập D gồm 2 câu văn bản:

#**Bước 2:** Tính cosine của góc giữa hai vector đặc trưng

$$\begin{aligned} A \cdot B &= \sum_{i=1}^n A_i B_i \\ &= (1 * 1) + (1 * 0) + (1 * 0) + (1 * 1) + (0 * 1) + (1 * 0) + (1 * 1) + (2 * 0) \\ &= 3 \end{aligned}$$

$$\sqrt{\sum_{i=1}^n A_i^2} = \sqrt{1 + 1 + 1 + 1 + 0 + 1 + 1 + 4} = \sqrt{10}$$

$$\sqrt{\sum_{i=1}^n B_i^2} = \sqrt{1 + 0 + 0 + 1 + 1 + 0 + 1 + 0} = \sqrt{4}$$

$$\text{cosine similarity} = \cos\theta = \frac{A \cdot B}{|A||B|} = \frac{3}{\sqrt{10} * \sqrt{4}} = 0.4743$$

Bước 3: đánh giá độ tương đồng, độ tương đồng giữa 2 câu doc_1 và doc_2 là: **0.4743**

ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

❑ Cosine similarity

- Cài đặt trên python
 - Xây dựng vector đặc trưng bằng Word2Vec

Source Code: https://github.com/thuy-nguyenthanh/Web_Mining_Class/blob/main/Chapter5/Exam51a.ipynb

ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

❑ Cosine similarity

- **Bài tập**, thực hiện các bước để tính độ tương đồng cho tập dữ liệu sau bằng phương pháp Cosine similarity:

Text1="The cat jumped over the fence"


Text2="The dog leaped across the barrier"

Text3="The rabbit hopped over the wall"

ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

□ Jaccard similarity

- Jaccard similarity đo lường mức độ giống nhau giữa hai văn bản, bằng cách tính tỉ lệ số phần tử chung giữa hai tập hợp và tổng số phần tử trong hai tập hợp đó.



Source: https://storage.googleapis.com/lids-media/images/jaccard_similarity.width-1200.jpg

ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

□ Jaccard similarity

- Các bước thực hiện:
 - **Bước 1:** Tiền xử lý văn bản, chuyển đổi văn bản thành tập hợp các từ;
 - **Bước 2:** Tính toán Jaccard similarity bằng cách lấy số lượng từ chung giữa hai văn bản chia cho tổng số lượng từ của hai văn bản đó;
 - **Bước 3:** Đánh giá mức độ tương đồng dựa trên giá trị Jaccard similarity, với giá trị từ 0 (không tương đồng) đến 1 (hoàn toàn tương đồng).

ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

□ Jaccard similarity

- Ví dụ, cho tập D gồm 2 câu văn bản:
doc_1 = "Data is the oil of the digital economy"
doc_2 = "Data is a new oil"

#Bước 1: Tiền xử lý văn bản, chuyển đổi văn bản thành tập hợp các từ;

words_doc1 = {'data', 'is', 'the', 'new', 'oil', 'of', 'digital', 'economy'}

words_doc2 = {'data', 'is', 'a', 'new', 'oil'}

ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

□ Jaccard similarity

- Ví dụ, cho tập D gồm 2 câu văn bản:


#**Bước 2:** Tính toán Jaccard similarity;

$$J(doc_1, doc_2) = \frac{\{'data', 'is', 'the', 'new', 'oil', 'of', 'digital', 'economy'\} \cap \{'data', 'is', 'a', 'new', 'oil'\}}{\{'data', 'is', 'the', 'new', 'oil', 'of', 'digital', 'economy'\} \cup \{'data', 'is', 'a', 'new', 'oil'\}}$$

$$= \frac{\{'data', 'is', 'new', 'oil'\}}{\{'data', 'a', 'of', 'is', 'economy', 'the', 'new', 'digital', 'oil'\}}$$

$$= \frac{4}{9} = 0.444$$

Bước 3: đánh giá độ tương đồng, độ tương đồng giữa 2 câu doc_1 và doc_2 là: **0.444**



ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

❑ Jaccard similarity

- Cài đặt trên python

Source Code: https://github.com/thuy-nguyenthanh/Web_Mining_Class/blob/main/Chapter5/Exam52.ipynb

ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

□ Jaccard similarity

- **Bài tập**, thực hiện các bước để tính độ tương đồng cho tập dữ liệu sau bằng phương pháp Jaccard similarity:

Text1="The cat jumped over the fence"


Text2="The dog leaped across the barrier"

Text3="The rabbit hopped over the wall"

ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

□ Euclidean distance

- **Euclidean distance** đo lường khoảng cách giữa hai văn bản trong không gian đa chiều, dựa trên **khoảng cách Euclidean giữa hai vector đặc trưng tương ứng với hai văn bản.**



Source: https://upload.wikimedia.org/wikipedia/commons/thumb/5/55/Euclidean_distance_2d.svg/1200px-Euclidean_distance_2d.svg.png

ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

□ Euclidean distance

- Các bước thực hiện:
 - **Bước 1:** Biểu diễn vector đặc trưng của văn bản: Bag-of-words, TF-IDF, Word embedding hoặc Doc2Vec;
 - **Bước 2:** Tính toán khoảng cách Euclidean giữa hai vector đặc trưng của hai văn bản đó;
 - **Bước 3:** Đánh giá mức độ tương đồng dựa trên giá trị độ tương đồng, giá trị Euclidean giữa các vector nào nhỏ nhất thì 2 câu đó có độ tương đồng là lớn nhất.

ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

❑ Euclidean distance

- Ví dụ, cho tập D gồm 2 câu văn bản:

Text1 = "I love ice cream"

Text2 = "I like ice cream"

Text3 = "I offer ice cream to the lady that I love"

#Bước 1: Biểu diễn vector đặc trưng của văn bản

Text/Word	I	love	ice	cream	like	offer	to	the	lady
Text 1	1	1	1	1	0	0	0	0	0
Text 2	1	0	1	1	1	0	0	0	0
Text 3	1	1	1	1	0	1	1	1	1

Source: <https://nikoskalikis.medium.com/text-similarity-euclidian-distance-vs-cosine-similarity-3a1167f686a>

ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

□ Euclidean distance

- Ví dụ, cho tập D gồm 2 câu văn bản:

#**Bước 2:** Tính toán khoảng cách Euclidean giữa hai vector đặc trưng

$$\text{dist}(X, Y) = \sqrt{\sum_1^n (x_i - y_i)^2}$$

Bước 3: đánh giá độ tương đồng, **câu 1** và **câu 2** có khoảng cách giữa hai văn bản nhỏ nhất thì có độ tương đồng lớn nhất.

Dist(text: 1, text : 2)

$$= \sqrt{(1-1)^2 + (1-0)^2 + (1-1)^2 + (1-1)^2 + (0-1)^2 + (0-0)^2 + (0-0)^2 + (0-0)^2 + (0-0)^2}$$
$$\simeq 1,414$$

Dist(text: 1, text : 3)

$$= \sqrt{(1-1)^2 + (1-1)^2 + (1-1)^2 + (1-1)^2 + (0-0)^2 + (0-1)^2 + (0-1)^2 + (0-1)^2 + (0-1)^2}$$
$$\simeq 2$$

Dist(text: 2, text : 3)

$$= \sqrt{(1-1)^2 + (0-1)^2 + (1-1)^2 + (1-1)^2 + (1-0)^2 + (0-1)^2 + (0-1)^2 + (0-1)^2 + (0-1)^2}$$
$$\simeq 2,45$$

ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

□ Euclidean distance

- Cài đặt trên python

Source Code: https://github.com/thuy-nguyenthanh/Web_Mining_Class/blob/main/Chapter5/Exam53.ipynb

ĐỘ ĐO TƯƠNG ĐỒNG VĂN BẢN

□ Euclidean similarity

- **Bài tập**, thực hiện các bước để tính độ tương đồng cho tập dữ liệu sau bằng phương pháp Euclidean similarity:

Text1="The cat jumped over the fence"

Text2="The dog leaped across the barrier"

Text3="The rabbit hopped over the wall"

PHÂN TÍCH ĐỘ TƯƠNG ĐỒNG CỦA VĂN BẢN

❑ Đánh giá độ tương đồng giữa các văn bản

- **Bước 1: Chuẩn bị dữ liệu**, dữ liệu được thu thập từ 3 bài báo điện tử

- Doc1: “ChatGPT Is Banned in Italy Over Privacy Concerns”

<https://www.nytimes.com/2023/03/31/technology/chatgpt-italy-ban.html>

- Doc2: “AI chatbot ChatGPT blocked in Italy over privacy concerns”

<https://www.abc.net.au/news/2023-04-01/chatgpt-ai-chatbot-blocked-italy-over-privacy-concerns/102175640>

- Doc3: “Manchester United F.C.”

https://en.wikipedia.org/wiki/Manchester_United_F.C.

Dữ liệu chỉ bao gồm nội dung văn bản, tổ chức thành 3 file: **Doc1.txt**, **Doc2.txt**, **Doc3.txt**

PHÂN TÍCH ĐỘ TƯƠNG ĐỒNG CỦA VĂN BẢN

❑ Đánh giá độ tương đồng giữa các văn bản

- **Bước 2: Tiền xử lý dữ liệu**, loại bỏ các stop words, chuyển đổi chữ hoa thành chữ thường, loại bỏ các ký tự đặc biệt, chuẩn hóa từ,...
 - **Bước 3: Xây dựng vector đặc trưng cho các file văn bản**, bằng TF-IDF, BOW, Word2vec,...
 - **Bước 4: Tính toán độ tương đồng**, sử dụng một phương pháp đo độ tương đồng như Cosine, Jaccard, Euclidean similarity, ...
 - **Bước 5: Đưa ra kết luận**, dựa trên độ tương đồng tính được, ta đưa ra kết luận về mức độ tương đồng giữa các file văn bản,...
- Sau đây là kết quả đánh giá, dựa trên vector đặc trưng BOW (CountVectorizer), độ đo Cosine:

	doc_1	doc_2	doc_3
doc_1	1.000000	0.666078	0.046005
doc_2	0.666078	1.000000	0.039957
doc_3	0.046005	0.039957	1.000000

Source Code: https://github.com/thuy-nguyenthanh/Web_Mining_Class/blob/main/Chapter5/Exam54a.ipynb

PHÂN TÍCH ĐỘ TƯƠNG ĐỒNG CỦA VĂN BẢN

❑ Đánh giá độ tương đồng giữa các văn bản

- Đánh giá độ tương đồng giữa 3 bài báo tiếng Việt

- Doc4: “ChatGPT Is Banned in Italy Over Privacy Concerns”

https://vi.wikipedia.org/wiki/X%E1%BB%AD_l%C3%BD_ng%C3%B4n_ng%E1%BB%AF_t%E1%BB%B1_nhi%C3%AAn

- Doc5: “Manchester United F.C.”

- Link: https://en.wikipedia.org/wiki/Manchester_United_F.C.

- Doc5: “Arsenal F.C.”

https://vi.wikipedia.org/wiki/Arsenal_F.C.

- Dữ liệu chỉ bao gồm nội dung văn bản, tổ chức thành 3 file: **Doc4.txt, Doc5.txt, Doc6.txt**
- Sau đây là kết quả đánh giá, dựa trên vector đặc trưng BOW (CountVectorizer), độ đo Cosine:

	doc_4	doc_5	doc_6
doc_4	1.000000	0.024140	0.034699
doc_5	0.024140	1.000000	0.712999
doc_6	0.034699	0.712999	1.000000

Source Code: https://github.com/thuy-nguyenthanh/Web_Mining_Class/blob/main/Chapter5/Exam54b.ipynb

PHÂN TÍCH ĐỘ TƯƠNG ĐỒNG CỦA VĂN BẢN

■ Bài tập nhóm



- Thực hiện crawl phần văn bản từ các chuyên mục web tin tức sau, mỗi chuyên mục 2 bài mới nhất:
 - **News1:** <https://vnexpress.net/rss/the-thao.rss>
 - **News2:** <https://vnexpress.net/rss/suc-khoe.rss>
 - **News3:** <https://vnexpress.net/rss/kinh-doanh.rss>
- Lưu file theo cú pháp: News11.txt, News12.txt, ... News21.txt, News22txt,...
- Thực hiện đánh giá mức độ tương đồng giữa các trang web;
- Sắp xếp theo thứ tự giảm dần các cặp tin tức có độ tương đồng giảm dần.

Yêu cầu:

- Code cần được tích hợp, để khi chạy 1 lần có thể thực hiện liên tục các yêu cầu trên và in kết quả lên màn hình.

CÁC THUẬT TOÁN PHÂN CỤM VĂN BẢN

- ❑ **K-Means:** tính toán khoảng cách giữa các điểm dữ liệu và các trung tâm cụm. Thuật toán nhằm tối thiểu hóa tổng khoảng cách giữa các điểm dữ liệu và trung tâm cụm.
- ❑ **Hierarchical Clustering** (Phân cụm theo thứ bậc): tính toán độ tương tự giữa các đối tượng và sau đó xây dựng một cây phân cấp. Các đối tượng tương tự nhau sẽ được gom vào cùng một cụm.




Source:

- <https://images.squarespace-cdn.com/content/v1/5acbddd3a25bf024c12f4c8b4/1608407348392-22767PJ7RQ85BD5RLSLZ/k-means-clustering.png>
- <https://www.researchgate.net/profile/Carsten-Walther/.../Example-of-hierarchical-clustering-clusters-are-consecutively-merged-with-the-most.png>

PHÂN CỤM VĂN BẢN VỚI THUẬT TOÁN K-MEAN

■ Thuật toán K-Mean

- K-means là một loại phương pháp học tập không giám sát, được sử dụng với các dữ liệu không được gán nhãn;
- Mục tiêu của thuật toán là chia dữ liệu thành K nhóm, dựa trên các điểm có độ tương đồng cao với nhau;



Bài toán với 3 clusters.

Sinh viên cần đọc thêm:

- <https://machinelearningcoban.com/2017/01/01/kmeans/>
- <https://towardsdatascience.com/text-clustering-using-k-means-ec19768aae48>
- <https://medium.com/@lucasdesa/text-clustering-with-k-means-a039d84a941b>

PHÂN CỤM VĂN BẢN VỚI THUẬT TOÁN K-MEAN

■ Các bước phân cụm văn bản với thuật toán K-Mean

- **Bước 1:** Tiền xử lý dữ liệu;
- **Bước 2:** Xây dựng vector đặc trưng cho văn bản, TF-IDF, BOW, Word2Vec,...;
- **Bước 3:** Chọn số nhóm K cần phân cụm, đây là một tham số quan trọng của thuật toán K-mean;
- **Bước 4:** Khởi tạo K điểm trung tâm ban đầu, chọn ngẫu nhiên K điểm từ các vector đặc trưng để đại diện cho các nhóm ban đầu;
- **Bước 5:** Bổ sung các văn bản vào các nhóm, tính khoảng cách giữa các điểm trung tâm và các vector đặc trưng của các văn bản và gán chúng vào nhóm có điểm trung tâm gần nhất;
- **Bước 6:** Cập nhật điểm trung tâm, tính trung bình của các vector đặc trưng của các văn bản trong mỗi nhóm và chọn các điểm trung tâm mới;
- **Bước 7:** Lặp lại bước 5 và 6, cho đến khi điểm trung tâm không thay đổi hoặc đạt đến một điều kiện dừng khác;
- **Đánh giá kết quả:** Đánh giá kết quả phân cụm bằng cách sử dụng các độ đo như độ tương đồng trong cùng một nhóm và độ khác biệt giữa các nhóm.

PHÂN CỤM VĂN BẢN VỚI THUẬT TOÁN K-MEAN

- Các bước phân cụm văn bản với thuật toán K-Mean



Hình ảnh động, minh họa quá trình phân cụm văn bản với K-Mean

Source: <https://douglasduhaime.com/assets/posts/semantic-vectors/images/kmeans.gif>


PHÂN CỤM VĂN BẢN VỚI THUẬT TOÁN K-MEAN

■ Đánh giá thuật toán K-Mean

- **Phương pháp Elbow Method (Khuỷu tay):** tính **SSE** cho mỗi giá trị k , và chọn giá trị k tại điểm "khuỷu tay" trên biểu đồ của **SSE**;
- **Phương pháp Silhouette Score (Điểm bóng):** tính Silhouette Score cho mỗi giá trị k , và chọn giá trị k có Silhouette Score cao nhất. Silhouette Score được tính bằng cách đo lường độ tương đồng giữa các điểm trong cùng một nhóm và độ khác biệt giữa các nhóm.
- **Phương pháp Gap Statistic (Thống kê khoảng cách):** so sánh **SSE** thực tế với **SSE** được tính toán từ các tập dữ liệu ngẫu nhiên để đánh giá số lượng nhóm tối ưu. Giá trị k tối ưu được chọn là giá trị k mà khoảng cách giữa SSE thực tế và SSE ngẫu nhiên lớn nhất.
- **Phương pháp Đường cong giảm dần:** tính khoảng cách giữa các điểm trung tâm của các nhóm liên tiếp và chọn giá trị k tại điểm mà khoảng cách giảm chậm nhất.
 - **SSE:** Tổng bình phương khoảng cách

PHÂN CỤM VĂN BẢN VỚI THUẬT TOÁN K-MEAN

- **Đánh giá thuật toán K-Mean**
 - Phương pháp Elbow Method (Khuỷu tay)



Khuỷu tay đang hình thành tại K=3

PHÂN CỤM VĂN BẢN VỚI THUẬT TOÁN K-MEAN

■ Đánh giá thuật toán K-Mean

- Ví dụ, xác định K cho tập dữ liệu sau bằng **Elbow Method**:


```
text_data = [  
    "The quick brown fox jumps over the lazy dog.",  
    "The quick brown fox jumps over the lazy dog.",  
    "The quick brown fox jumps over the lazy dog and runs away.",  
    "The lazy dog is not always quick to jump.",  
    "The brown fox is quick and agile.",  
    "The quick brown fox is a symbol of speed and cunning.",  
    "The lazy dog is a symbol of relaxation and leisure."]
```

Source Code: https://github.com/thuy-nguyenthao/Web_Mining_Class/blob/main/Chapter5/Exam55a.ipynb

PHÂN CỤM VĂN BẢN VỚI THUẬT TOÁN K-MEAN

■ Đánh giá thuật toán K-Mean

- Ví dụ, xác định K cho tập dữ liệu sau bằng **Elbow Method**:



WCSS: Within-Cluster Sum of Square | **Tổng bình phương** giữa các điểm trung tâm trong các cluster, đơn vị dùng để đo lường khoảng cách giữa các cluster

PHÂN CỤM VĂN BẢN VỚI THUẬT TOÁN K-MEAN

■ Đánh giá thuật toán K-Mean

- Ví dụ, xác định K cho tập dữ liệu sau bằng **Silhouette Score**:

```
text_data = [  
    "The quick brown fox jumps over the lazy dog.",  
    "The quick brown fox jumps over the lazy dog.",  
    "The quick brown fox jumps over the lazy dog and runs away.",  
    "The lazy dog is not always quick to jump.",  
    "The brown fox is quick and agile.",  
    "The quick brown fox is a symbol of speed and cunning.",  
    "The lazy dog is a symbol of relaxation and leisure."]
```


Source Code:

https://github.com/thuy-nguyenthanh/Web_Mining_Class/blob/main/Chapter5/Exam55b.ipynb

PHÂN CỤM VĂN BẢN VỚI THUẬT TOÁN K-MEAN

■ Đánh giá thuật toán K-Mean

- Ví dụ, xác định K cho tập dữ liệu sau bằng **Silhouette Score**:



PHÂN CỤM VĂN BẢN VỚI THUẬT TOÁN K-MEAN

■ Đánh giá thuật toán K-Mean

- Ví dụ, phân cụm ý kiến phản hồi của khách hàng về dịch vụ ngân hàng
 - Dữ liệu được đặt trong file **consumer_complaints.csv**, có **715,438** phản hồi;
 - Gồm **18** trường thông tin:
 - date_received
 - product
 - sub_product
 - issue
 - sub_issue
 - **consumer_complaint_narrative** → được chọn để làm dữ liệu phân cụm
 - company_public_response
 - company
 - state
 - zipcode
 - tags
 - consumer_consent_provided
 - submitted_via
 - date_sent_to_company
 - company_response_to_consumer
 - timely_response
 - consumer_disputed?
 - complaint_id

PHÂN CỤM VĂN BẢN VỚI THUẬT TOÁN K-MEAN

▪ Đánh giá thuật toán K-Mean

- Ví dụ, phân cụm ý kiến phản hồi của khách hàng về dịch vụ ngân hàng
 - Các bước thực hiện phân cụm dữ liệu:
 1. Tách từ;
 2. Tiền xử lý;
 3. Xây dựng vector đặc trưng TF-IDF;
 4. Chạy các mô hình lựa chọn tham số K (Elbow Method, Silhouette Score,...);
 5. Chạy thuật toán K-means;
 6. Đo lường và đánh giá kết quả;
 7. Trực quan hóa bằng WordClouds hoặc thống kê tần suất từ theo từng cụm;


Source Code:

https://github.com/thuy-nguyenthanh/Web_Mining_Class/blob/main/Chapter5/Exam56.ipynb

PHÂN CỤM VĂN BẢN VỚI THUẬT TOÁN K-MEAN

■ Đánh giá thuật toán K-Mean

- Ví dụ, phân cụm ý kiến phản hồi của khách hàng về dịch vụ ngân hàng
 - Kết quả phân tích tối ưu tham số K bằng **Elbow Method** (Khuỷu tay)




WCSS: Within-Cluster Sum of Square | **Tổng bình phương** giữa các điểm trung tâm trong các cluster, đơn vị dùng để đo lường khoảng cách giữa các cluster

PHÂN CỤM VĂN BẢN VỚI THUẬT TOÁN K-MEAN

■ Đánh giá thuật toán K-Mean

- Ví dụ, phân cụm ý kiến phản hồi của khách hàng về dịch vụ ngân hàng
 - Kết quả phân tích tối ưu tham số K bằng **Silhouette Score** (Điểm bóng)



PHÂN CỤM VĂN BẢN VỚI THUẬT TOÁN K-MEAN

▪ Đánh giá thuật toán K-Mean

- Ví dụ, phân cụm ý kiến phản hồi của khách hàng về dịch vụ ngân hàng

- **Số lượng ý kiến trên mỗi cluster:**

- Cluster 0: 196
- Cluster 1: 96
- Cluster 2: 120
- Cluster 3: 132
- Cluster 4: 173
- Cluster 5: 101
- Cluster 6: 84
- Cluster 7: 98

- **Top 5 từ ở gần tâm của mỗi cluster:**

- Cluster 0 words: receiv, would, credit, inform, letter, time,
- Cluster 1 words: loan, year, payment, pay, would, call,
- Cluster 2 words: debt, collect, credit, report, compani, account,
- Cluster 3 words: payment, month, account, pay, make, call,
- Cluster 4 words: report, credit, credit, account, inform, collect,
- Cluster 5 words: call, ask, day, time, back, compani,
- Cluster 6 words: bank, account, credit, inform, could, call,
- Cluster 7 words: account, report, credit, inform, need, get,

PHÂN CỤM VĂN BẢN VỚI THUẬT TOÁN K-MEAN

■ Đánh giá thuật toán K-Mean

- Ví dụ, phân cụm ý kiến phản hồi của khách hàng về dịch vụ ngân hàng
 - Kết quả phân cụm với $K=8$

