

BÀI GIẢNG
KHAI PHÁ DỮ LIỆU WEB
CHƯƠNG 6.
PHÂN LỚP VĂN BẢN

NGUYỄN THÀNH THỦY

BỘ MÔN TIN HỌC QUẢN LÝ

TRƯỜNG ĐẠI HỌC KINH TẾ, ĐẠI HỌC ĐÀ NẴNG

THUYNT@DUE.EDU.VN


NỘI DUNG

- ❑ Tổng quan về phân lớp văn bản
- ❑ Các phương pháp phân lớp văn bản
- ❑ Đánh giá hiệu suất mô hình học máy
- ❑ Phân loại tin nhắn SMS

TỔNG QUAN VỀ PHÂN LỚP VĂN BẢN

❑ Khái niệm

- **Phân lớp văn bản (Text Classification)** là một kỹ thuật trong lĩnh vực NLP, dùng để **phân loại các văn bản vào các nhóm tương ứng** với các chủ đề khác nhau;
- Là một bài toán **học có giám sát**, dữ liệu được gán nhãn với các nhãn lớp tương ứng, **mô hình máy học được huấn luyện để học cách dự đoán nhãn của các văn bản mới đưa vào**;



TỔNG QUAN VỀ PHÂN LỚP VĂN BẢN

❑ Các ứng dụng của phân lớp văn bản

▪ Phân loại thư rác

(Spam classification)




Image Source: <https://i1.wp.com/www.opinosis-analytics.com>,...

▪ Phân loại các bài báo và blog

(Classifying news articles and blogs)




Image Source: <https://cdn.analyticsvidhya.com/wp-content/>...

TỔNG QUAN VỀ PHÂN LỚP VĂN BẢN

❑ Các ứng dụng của phân lớp văn bản

■ Phân loại yêu cầu hỗ trợ khách hàng

(Categorize customer support requests)




Image Source: <https://assets-global.website-files.com/...>

■ Phát hiện lời nói căm thù

(Hate speech detection)




Image Source: <https://repository-images.githubusercontent.com//...>

CÁC PHƯƠNG PHÁP PHÂN LỚP VĂN BẢN

❑ Các phương pháp cơ bản

- Dựa trên quy tắc (Rule-based text classification)
- Dựa trên mô hình học máy (Machine learning-based text classification)

CÁC PHƯƠNG PHÁP PHÂN LỚP VĂN BẢN

❑ Dựa trên quy tắc (Rule-based text classification)

- Phân lớp văn bản dựa trên quy tắc là một kỹ thuật **sử dụng các quy tắc ngữ nghĩa hoặc cú pháp** nhất định để xác định chủ đề của một văn bản;
- Ví dụ, các quy tắc **dựa vào các từ khóa** nhất định trong văn bản, hoặc **dựa trên cấu trúc của văn bản như tiêu đề, đoạn văn, hoặc thẻ HTML**;
- **Hạn chế:**
 - Không tự động học được từ dữ liệu, khi có thêm dữ liệu mới hoặc thay đổi trong văn bản, các quy tắc cũng phải được cập nhật thủ công;
 - Phương pháp này có thể bị sai sót nếu quy tắc không được thiết kế đầy đủ hoặc văn bản không phù hợp với quy tắc;
- Phân lớp văn bản dựa trên quy tắc được sử dụng để phân loại các văn bản đơn giản và có cấu trúc rõ ràng.

CÁC PHƯƠNG PHÁP PHÂN LỚP VĂN BẢN

❑ Dựa trên quy tắc (Rule-based text classification)

- Ví dụ, phân loại email dựa vào quy tắc, ta có thể sử dụng các quy tắc như sau:
 - Nếu email có tiêu đề chứa từ "**promotion**", "**sale**", "**discount**",... thì đó là email quảng cáo;
 - Nếu email có tiêu đề chứa từ "**urgent**", "**important**", "**deadline**",... thì đó là email quan trọng;
 - Nếu email có nội dung chứa từ "**meeting**", "**appointment**", "**schedule**",... thì đó là email về lịch trình;




Image Source: https://res.cloudinary.com/hevo/image/upload/c_scale,w_526,h_342/...

CÁC PHƯƠNG PHÁP PHÂN LỚP VĂN BẢN

- ❑ **Dựa trên các mô hình học máy (Machine learning-based text classification)**
 - Phân lớp văn bản dựa trên mô hình học máy là một phương pháp sử dụng các thuật toán học máy để **học từ các tập dữ liệu đã được gán nhãn**, và **tạo ra một mô hình có thể dự đoán nhãn của các văn bản mới dựa trên các đặc trưng của chúng**;
 - Là một **phương pháp phân lớp văn bản hiệu quả** và được **sử dụng rộng rãi** trong các ứng dụng thực tế.

CÁC PHƯƠNG PHÁP PHÂN LỚP VĂN BẢN

❑ Dựa trên các mô hình học máy (Machine learning-based text classification)

- Các giai đoạn trong **đào tạo** và **dự đoán** phân lớp văn bản:




Image Source: https://landen.imgix.net/blog_dAYMuhFXJnoIGCzL/assets/yQYaBiqkVVmVhkCU.png

CÁC PHƯƠNG PHÁP PHÂN LỚP VĂN BẢN

❑ Dựa trên các mô hình học máy (Machine learning-based text classification)

- Ví dụ, để phân loại các bài báo thành các chủ đề khác nhau.
 - Xây dựng một tập dữ liệu gồm các bài báo đã được gán nhãn thành các chủ đề khác nhau;
 - Sử dụng các mô hình học máy để học từ các đặc trưng của các bài báo đó, ví dụ như số lượng từ khóa, tần suất xuất hiện của các từ,...
 - Sử dụng các mô hình đã học để phân lớp các bài báo mới.




Image Source: <https://static.hindawi.com/articles/cin/volume-2022/1883698/figures/1883698.fig.002.jpg>

CÁC PHƯƠNG PHÁP PHÂN LỚP VĂN BẢN

❑ Các bước xây dựng mô hình học máy phân lớp văn bản

- **Bước 1.** Chuẩn bị dữ liệu;
- **Bước 2.** Tiền xử lý dữ liệu;
- **Bước 3.** Xây dựng vector đặc trưng;
- **Bước 4.** Huấn luyện mô hình học máy;
- **Bước 5.** Đánh giá hiệu suất của mô hình học máy.

ĐÁNH GIÁ HIỆU SUẤT MÔ HÌNH HỌC MÁY

❑ Ma trận nhầm lẫn (Confusion Matrix)

- Ma trận nhầm lẫn (ma trận lỗi) là một bố cục bảng cụ thể cho phép hình dung hiệu suất của một thuật toán;
- Là một trong những kỹ thuật đo lường hiệu suất phổ biến nhất và được sử dụng rộng rãi cho các mô hình phân loại;

		Actual Values	
		Positive	Negative
Predicted Values	Positive	True Positive	False Positive
	Negative	False Negative	True Negative

Image Source: <https://media.geeksforgeeks.org/wp-content/uploads/20221031145731/ConfusionMatrix2.png>

Sinh viên đọc thêm:

- <https://machinelearningcoban.com/2017/08/31/evaluation/>
- <https://www.noron.vn/post/tim-hieu-ve-confusion-matrix-trong-machine-learning-1fz9nhqo5ux>

Bài giảng KHAI PHÁ DỮ LIỆU WEB - Nguyễn Thành Thủy, MIS Dept. - DUE

ĐÁNH GIÁ HIỆU SUẤT MÔ HÌNH HỌC MÁY

❑ Ma trận nhầm lẫn (ma trận lỗi / Confusion Matrix)

Ví dụ: Vào ngày D, tại bệnh viện H có **100 bệnh nhân** đến khám một loại bệnh, giả sử biết trước trong 100 bệnh nhân có **60 người có bệnh**, **40 người không có bệnh**. Sau khi thăm khám, bệnh viện đưa ra kết quả:

- Trong **60 người có bệnh**: thì có **45 người** chuẩn đoán có bệnh, **15 người** chuẩn đoán không mắc bệnh.
- Trong **40 người không có bệnh**: thì có **30 người** chuẩn đoán không mắc bệnh, **10 người** chuẩn đoán là mắc bệnh.

Thực tế	Dương tính	Âm tính		Thực tế	Dương tính	Âm tính
Dự đoán				Dự đoán		
Dương tính	45	10		Dương tính	True Positive (TP)	False Positive (FP)
Âm tính	15	30		Âm tính	False Negative (FN)	True Negative (TN)

ĐÁNH GIÁ HIỆU SUẤT MÔ HÌNH HỌC MÁY

❑ Ma trận nhầm lẫn (ma trận lỗi / Confusion Matrix)

Ví dụ:

Thực tế Dự đoán	Dương tính	Âm tính		Thực tế Dự đoán	Dương tính	Âm tính
Dương tính	45	10		Dương tính	True Positive (TP)	False Positive (FP)
Âm tính	15	30		Âm tính	False Negative (FN)	True Negative (TN)

- **Condition Positive (P):** Tổng số ca dương tính thực tế;
- **Condition Negative (N):** Tổng số ca âm tính thực tế;
- **True Positive (TP):** Số các ca dự đoán dương tính ĐÚNG (dương tính thật);
- **True Negative (TN):** Số các ca dự đoán âm tính ĐÚNG (âm tính thật);
- **False Positive (FP):** Số các ca dự đoán dương tính SAI (dương tính giả);
- **False Negative (FN):** Số các ca dự đoán âm tính SAI (âm tính giả);

ĐÁNH GIÁ HIỆU SUẤT MÔ HÌNH HỌC MÁY

❑ Độ chính xác của mô hình (Accuracy)

- Tỷ lệ giữa tổng số ca bệnh được dự đoán đúng với tổng số bệnh nhân đến khám:

$$Accuracy = \frac{TP + TN}{P + N} = \frac{TP + TN}{TP + FP + TN + FN}$$

- **Accuracy** = $75 / (45 + 10 + 15 + 30) = \mathbf{0.75}$

→ Độ chính xác trong kết quả chẩn đoán bệnh của bệnh viện X là: **75%**

Thực tế	Dương tính	Âm tính		Thực tế	Dương tính	Âm tính
Dự đoán				Dự đoán		
Dương tính	45	10		Dương tính	True Positive (TP)	False Positive (FP)
Âm tính	15	30		Âm tính	False Negative (FN)	True Negative (TN)

ĐÁNH GIÁ HIỆU SUẤT MÔ HÌNH HỌC MÁY

❑ Precision và Recall

- **Precision:** là tỉ lệ bệnh nhân được chẩn đoán có bệnh là ĐÚNG với thực tế (True Positive) trong tổng số bệnh nhân được chẩn đoán là có bệnh (True Positive + False Positive);
- **Recall:** là tỉ lệ bệnh nhân được chẩn đoán có bệnh là ĐÚNG với thực tế (True Positive) trong tổng số bệnh nhân **thật sự có bệnh** (Actually Positive);




Image Source: https://machinelearningcoban.com/assets/33_evaluation/PR.png

Sinh viên đọc thêm: http://scikit-learn.org/stable/auto_examples/model_selection/plot_precision_recall.html

ĐÁNH GIÁ HIỆU SUẤT MÔ HÌNH HỌC MÁY

❑ Precision và Recall

- **Precision** có giá trị càng lớn, thể hiện độ chính xác (**Accuracy**) của mô hình phân lớp càng lớn;
- **Recall** giá trị càng lớn, thể hiện tỉ lệ chẩn đoán sai các bệnh nhân thực sự **có bệnh (Positive)** là thấp;
- Một mô hình phân lớp tốt là mô hình có cả **Precision và Recall đều cao**, càng gần một càng tốt;

$$\text{Precision} = TP / (TP + FP) = 45 / (45 + 10) = \mathbf{0.82}$$

→ Tỉ lệ chẩn đoán ĐÚNG (thật sự có bệnh) trên tổng số ca bệnh được chẩn đoán có bệnh là: **82%**

$$\text{Recall} = TP / (TP + FN) = 45 / (45 + 15) = \mathbf{0.75}$$

→ Tỉ lệ chẩn đoán ĐÚNG (thật sự có bệnh) trên tổng số ca bệnh thật sự có bệnh là: **75%**

Thực tế	Dương tính	Âm tính		Thực tế	Dương tính	Âm tính
Dự đoán				Dự đoán		
Dương tính	45	10		Dương tính	True Positive (TP)	False Positive (FP)
Âm tính	15	30		Âm tính	False Negative (FN)	True Negative (TN)

ĐÁNH GIÁ HIỆU SUẤT MÔ HÌNH HỌC MÁY

❑ F1-score

- **F1-score** (F-measure) là sự kết hợp giữa 2 chỉ số **Precision** và **Recall**;
- F1-score có giá trị càng cao, thể hiện độ chính xác của mô hình phân lớp càng lớn;

$$\mathbf{F1 - score} = 2 * \frac{\text{Precision} * \text{Recall}}{\text{Precision} + \text{Recall}}$$


$$\text{F1-score} = 2 * (0.82 * 0.75) / (0.82 + 0.75) = \mathbf{0.78}$$

→ Điểm F1-score của kết quả chẩn đoán bệnh của bệnh viện X đạt: **78%**

ĐÁNH GIÁ HIỆU SUẤT MÔ HÌNH HỌC MÁY

❑ ROC Curve và AU Curve

- **ROC Curve** (Receiver Operating Characteristic curve / Đường cong ROC), đường cong đặc trưng, phản ánh tỉ lệ giữa hai giá trị: **Dương tính được phát hiện đúng** bởi mô hình (True Positive Rate – TPR) và **Âm tính được phát hiện sai** bởi mô hình (False Positive Rate - FPR);
- Trục tung thể hiện giá trị **TPR**, trục hoành thể hiện giá trị **FPR**;
- Đường cong ROC **gần với góc trên bên trái** của đồ thị, tức là có TPR cao và FPR thấp, thể hiện độ chính xác của mô hình phân lớp cao;
- Diện tích dưới đường cong ROC (Area Under the ROC Curve - AUC) cũng được sử dụng để đánh giá hiệu suất của mô hình, với giá trị AUC càng gần 1 thì mô hình càng tốt.



Sinh viên đọc thêm:

- <https://pub.towardsai.net/the-beginners-guide-to-the-roc-curve-and-auc-40585bada247>
- https://scikit-learn.org/stable/auto_examples/model_selection/plot_roc.html

PHÂN LOẠI TIN NHẮN SMS

❑ Thực hành phân loại tin nhắn SMS

■ Mô tả dữ liệu:

- File dữ liệu: `\\Data\\spam.csv`
- Gồm 5572 dòng tin nhắn văn bản (ngôn ngữ tiếng Anh) đã được gán nhãn, và 05 cột dữ liệu;
- Cột v1 chứa nhãn của tin nhắn tương ứng, gồm 2 nhãn: **spam** (tin nhắn spam), **ham** (tin nhắn thường). Cột v2 chứa nội dung tin nhắn;

■ Các bước thực hiện xây dựng mô hình học máy để phân loại tin nhắn:

- **Bước 1.** Chuẩn bị dữ liệu;
- **Bước 2.** Tiền xử lý dữ liệu;
- **Bước 3.** Xây dựng vector đặc trưng;
- **Bước 4.** Huấn luyện mô hình học máy;
- **Bước 5.** Đánh giá hiệu suất của mô hình học máy.

PHÂN LOẠI TIN NHẮN SMS

❑ Thực hành phân loại tin nhắn SMS

- Chia tập dữ liệu huấn luyện và kiểm thử: **66% train - 33% test**;
- Trích xuất đặc trưng văn bản bằng **Bag of Words**;
- Huấn luyện dữ liệu bằng mô hình hồi quy tuyến tính (Logistic Regression);

- Đánh giá kết quả mô hình phân loại:

- Confusion matrix

	ham	spam
ham	1600	2
spam	31	206

- Độ chính xác Accuracy = **98%**

	precision	recall	f1-score	support
ham	0.98	1.00	0.99	1602
spam	0.99	0.87	0.93	237
accuracy			0.98	1839
macro avg	0.99	0.93	0.96	1839
weighted avg	0.98	0.98	0.98	1839

PHÂN LOẠI CẢM XÚC VĂN BẢN

❑ Bài tập Nhóm

- Cho dữ liệu review của khách hàng (file Review.zip), trong 2 thư mục neg và pos, bao gồm dữ liệu văn bản đã được gán nhãn tiêu cực (negative) và tích cực (positive);
- Xây dựng mô hình học máy, phân lớp cảm xúc (tích cực và tiêu cực) dựa trên câu văn bản đầu vào;
- Thực nghiệm mô hình với các thuật toán khác nhau: Naive Bayes, Support Vector Machines (SVM), Random Forest, K-Nearest Neighbors;
- Đánh giá hiệu suất của mô hình trên.