

BÀI GIẢNG KHAI PHÁ DỮ LIỆU WEB

CHƯƠNG 3.

TIỀN XỬ LÝ VÀ PHÁM PHÁ DỮ LIỆU VĂN BẢN

NGUYỄN THÀNH THỦY

BỘ MÔN TIN HỌC QUẢN LÝ

TRƯỜNG ĐẠI HỌC KINH TẾ, ĐẠI HỌC ĐÀ NẴNG

THUYNT@DUE.EDU.VN


NỘI DUNG

- ❑ Tổng quan về xử lý ngôn ngữ tự nhiên
- ❑ Tiền xử lý dữ liệu văn bản
- ❑ Khám phá dữ liệu văn bản

3.1 TỔNG QUAN VỀ XỬ LÝ NGÔN NGỮ TỰ NHIÊN - NLP

❑ Ngôn ngữ tự nhiên (Natural Language):

- Công cụ để giao tiếp giữa con người với con người, giữa con người với máy tính;
- Định dạng: tiếng nói, văn bản, hình ảnh, video;
- Thể loại: các ngôn ngữ giao tiếp, ngôn ngữ lập trình;




3.1 TỔNG QUAN VỀ XỬ LÝ NGÔN NGỮ TỰ NHIÊN - NLP

□ Xử lý ngôn ngữ tự nhiên – NLP

- Là khái niệm để chỉ các kỹ thuật, phương pháp thao tác trên ngôn ngữ tự nhiên bằng máy tính (*ví dụ: tiếng Việt, tiếng Anh, tiếng Nhật,...*);
- NLP là một nhánh nghiên cứu của trí tuệ nhân tạo, trong đó tập trung vào việc cho phép máy tính hiểu và xử lý được ngôn ngữ của con người.

3.1 TỔNG QUAN VỀ XỬ LÝ NGÔN NGỮ TỰ NHIÊN - NLP

❑ Các vấn đề chính trong xử lý ngôn ngữ tự nhiên



3.1 TỔNG QUAN VỀ XỬ LÝ NGÔN NGỮ TỰ NHIÊN - NLP

❑ Các vấn đề chính trong xử lý ngôn ngữ tự nhiên

- **Natural Language Generation (NLG):** Hệ thống sinh văn bản tự động
 - Là quá trình tạo ra các cụm từ và câu có nghĩa dưới dạng ngôn ngữ giao tiếp của con người;
 - Ứng dụng: dịch máy, chuyển giọng nói thành văn bản, chatbot, tự động sửa văn bản hoặc tự động hoàn thành văn bản;

Natural Language Generation



Chat Generative Pre-training Transformer




Đọc thêm:

- <https://vinbigdata.com/tong-quan-ve-he-thong-sinh-van-ban-tu-dong-natural-language-generation-nlg/>
- <https://viblo.asia/p/cach-tao-ra-ngon-ngu-con-nguoi-tu-hu-vo-natural-language-generation-voi-language-model-GrLZD00JZk0>
- <https://viblo.asia/p/cac-giai-thuat-tim-kiem-thuong-duoc-su-dung-trong-natural-language-generation-3P0IP3doZox>

3.1 TỔNG QUAN VỀ XỬ LÝ NGÔN NGỮ TỰ NHIÊN - NLP

❑ Các vấn đề chính trong xử lý ngôn ngữ tự nhiên

- **Natural Language Understanding (NLU):** Hiểu ngôn ngữ tự nhiên
 - Giúp máy tính có khả năng "hiểu" được ý nghĩa của câu hoặc đoạn văn bản, có thể trả lời các câu hỏi hoặc thực hiện các tác vụ tương tự như con người;
 - NLU được sử dụng trong nhiều ứng dụng AI: nhận dạng giọng nói, dịch thuật tự động, phân tích ý kiến và ChatBot.



Source:

- <https://devopedia.org/images/article/259/5744.1582003376.png>
- <https://research.aimultiple.com/wp-content/uploads/2020/05/nlu2.png>

3.1 TỔNG QUAN VỀ XỬ LÝ NGÔN NGỮ TỰ NHIÊN - NLP

❑ Các vấn đề chính trong xử lý ngôn ngữ tự nhiên

■ Information Extraction (IE): Trích xuất thông tin

- IE là quá trình tự động trích xuất các thông tin có cấu trúc, từ văn bản không có cấu trúc hoặc bán cấu trúc.
 - **Ví dụ:** trích xuất tên người, địa chỉ email, số điện thoại, địa chỉ và các thông tin khác từ các văn bản như email, trang web, tài liệu hợp đồng,...
- IE được sử dụng rộng rãi trong các ứng dụng tự động hóa trích xuất thông tin, từ: hồ sơ bệnh án, theo dõi ý kiến của khách hàng trên mạng xã hội, phân tích tin tức để theo dõi các sự kiện quan trọng,...



Alexis Sanchez stepped up his preparations for Manchester United's FA Cup clash against Yeovil when he checked in for training on Thursday. The Chile star is in line to make his debut for the Red Devils in the fourth round tie at Huish Park following his move to Old Trafford. Sanchez met his new team-mates for the first time on Wednesday and could go straight into the matchday squad to face the Glovers. Jose Mourinho has so far given no indication on the strength of team that he will take to Somerset, but Sanchez will be keen to make his debut.



3.1 TỔNG QUAN VỀ XỬ LÝ NGÔN NGỮ TỰ NHIÊN - NLP

❑ Các bài toán cơ bản trong NLP

■ Mô hình hóa ngôn ngữ (Language modelling)

- Mô hình dự đoán từ tiếp theo xuất hiện theo trình tự, dựa trên lịch sử của các từ đã xuất hiện trước đó. Một số ứng dụng như: nhận dạng giọng nói, nhận dạng ký tự quang học, nhận dạng chữ viết tay, dịch máy và sửa lỗi chính tả.

■ Phân loại văn bản (Text classification)

- Gán tài liệu văn bản cho một danh mục cho trước dựa trên nội dung. Phân loại văn bản là ứng dụng phổ biến nhất của NLP. Một số ứng dụng như: phát hiện thư rác, phân tích cảm xúc,...

■ Trích xuất thông tin (Information extraction)

- Tự động trích xuất thông tin từ các tài liệu văn bản. Ví dụ về lịch sự kiện từ email hoặc tên của những người được đề cập trong một bài đăng trên mạng xã hội,...

■ Truy xuất thông tin (Information retrieval)

- Google là một loại hệ thống Truy xuất Thông tin (IR) điển hình. IR làm nhiệm vụ tìm kiếm các tài liệu có liên quan từ một bộ dữ liệu lớn các tài liệu liên quan đến truy vấn do người dùng thực hiện.

3.1 TỔNG QUAN VỀ XỬ LÝ NGÔN NGỮ TỰ NHIÊN - NLP

❑ Các bài toán cơ bản trong NLP

■ Tác tử phần mềm hội thoại (Conversational agent)

- Xây dựng các hệ thống đối thoại mô phỏng các tương tác của con người (Chatbot). Ví dụ: Alexa, Siri, Google Home, Cortana, trợ lý ảo ViVi,...

■ Tóm tắt văn bản (Text summarization)

- Tự động tóm tắt là quá trình rút ngắn một tập hợp dữ liệu để tạo một tập hợp con đại diện cho thông tin quan trọng nhất hoặc có liên quan trong nội dung gốc.

■ Hỏi đáp (Question answering)

- Hỏi đáp là bài toán xây dựng các hệ thống có thể tự động trả lời cho các câu hỏi do con người đặt ra bằng ngôn ngữ tự nhiên. Ví dụ: ChatGPT

■ Dịch máy (Machine translation)

- Là một nhánh con của ngôn ngữ học tính toán liên quan đến việc chuyển đổi một đoạn văn bản từ ngôn ngữ này sang ngôn ngữ khác. Một ứng dụng phổ biến của loại này là Google Dịch.

■ Mô hình hóa chủ đề (Topic modelling)

- Là một kỹ thuật Học máy giúp khám phá cấu trúc chủ đề của một bộ tài liệu lớn, được sử dụng trên nhiều lĩnh vực khác nhau – như Văn học, và Tin sinh học.

3.1 TỔNG QUAN VỀ XỬ LÝ NGÔN NGỮ TỰ NHIÊN - NLP

❑ Các bài toán cơ bản trong NLP

SENTIMENT ANALYSIS FOR HOTEL REVIEWS

Câu Review:

Đây là khách sạn người nước ngoài ở nhiều nên chi phí hơi cao. Gia đình có trẻ nhỏ rất phù hợp nghỉ ở đây. Không gian sạch sẽ, view đẹp, nhân viên nhiệt tình rất thoải mái. Chai nước suối miễn phí trong phòng vô chai củ kỳ làm cho khách cảm thấy nước sẽ ko sạch. Bữa sáng ngon tuyệt, ngắm hoàng hôn tuyệt đẹp, Spa thư giãn cũng tuyệt vời. Nhân viên nhiệt tình vui vẻ, hỗ trợ khách hàng rất tốt, vị trí view đẹp, vào trung tâm thị trấn cũng thuận tiện, Resort mới nên rất sạch sẽ. Bãi biển tuyệt đẹp và sạch sẽ. Nên thay đổi. Ghế nằm ở hồ bơi hơi ít và thường xuyên full. Hàng ngày nên có trái cây chào buổi sáng thì tuyệt hơn rất nhiều. Nhân viên rất thân thiện. Mọi thứ đều tuyệt vời, chắc chắn sẽ quay lại khi có dịp đến Phú Quốc ♥.

Reset

Negative

Positive

Normal

1. Tiền xử lý (Show)

2. Phân tích cảm xúc (Show)

đây là khách_sạn người nước_ngoài ở nhiều nên chi_phí hơi cao
gia_đình có trẻ nhỏ rất phù_hợp nghỉ ở đây
không_gian sạch_sẽ tầm_nhìn đẹp nhân_viên nhiệt_tình rất
thoải_mái
chai nước suối miễn_phí trong phòng vô_chai củ_kỳ làm cho khách
cảm_thấy nước sẽ không sạch
bữa sáng ngon tuyệt ngắm hoàng_hôn tuyệt đẹp spa thư_giãn
cũng tuyệt_vời
nhân_viên nhiệt_tình vui_vẻ hỗ_trợ khách_hàng rất tốt vị_trí
tầm_nhìn đẹp vào trung_tâm thị_trấn cũng thuận_tiện resort mới
nên rất sạch_sẽ
bãi biển tuyệt đẹp và sạch_sẽ
nên thay_đổi
ghế nằm ở hồ bơi hơi ít và thường_xuyên full
hàng ngày nên có trái_cây chào buổi sáng thì tuyệt hơn rất nhiều

đây là khách_sạn người nước_ngoài ở nhiều nên chi_phí hơi cao
gia_đình có trẻ nhỏ rất phù_hợp nghỉ ở đây
không_gian sạch_sẽ tầm_nhìn đẹp nhân_viên nhiệt_tình rất
thoải_mái
chai nước suối miễn_phí trong phòng vô_chai củ_kỳ làm cho khách
cảm_thấy nước sẽ không sạch
bữa sáng ngon tuyệt ngắm hoàng_hôn tuyệt đẹp spa thư_giãn
cũng tuyệt_vời
nhân_viên nhiệt_tình vui_vẻ hỗ_trợ khách_hàng rất tốt vị_trí
tầm_nhìn đẹp vào trung_tâm thị_trấn cũng thuận_tiện resort mới
nên rất sạch_sẽ
bãi biển tuyệt đẹp và sạch_sẽ

ghế nằm ở hồ bơi hơi ít và thường xuyên full
hàng ngày nên có trái cây chào buổi sáng thì tuyệt hơn rất nhiều
nhân viên rất thân thiện
mọi thứ đều tuyệt vời chắc chắn sẽ quay lại khi có dịp đến Phú Quốc rất tốt

ghế nằm ở hồ bơi hơi ít và thường xuyên full
hàng ngày nên có trái cây chào buổi sáng thì tuyệt hơn rất nhiều
nhân viên rất thân thiện
mọi thứ đều tuyệt vời chắc chắn sẽ quay lại khi có dịp đến Phú Quốc rất tốt

4. Chấm điểm chất lượng dịch vụ (Show)

3. Tách thực thể (Show)

6.2 điểm

Nhân viên

Sự tiện lợi

Phòng nghỉ

Dịch vụ

75% 25%

57% 43%

80% 20%

40% 60%

Tích cực

Tiêu cực

đây là khách_sạn người nước_ngoài ở nhiều nên chi_phí hơi cao
gia_đình có trẻ nhỏ rất phù_hợp nghỉ ở đây
không_gian sạch_sẽ tầm_nhìn đẹp nhân_viên nhiệt_tình rất thoải_mái
chai nước suối miễn_phí trong phòng vô_chai củ_kỳ làm cho khách cảm_thấy
nước sẽ không sạch
bữa sáng ngon tuyệt ngắm hoàng_hôn tuyệt đẹp spa thư_giãn cũng tuyệt_vời
nhân_viên nhiệt_tình vui_vẻ hỗ_trợ khách_hàng rất tốt vị_trí tầm_nhìn đẹp
vào trung_tâm thị_trấn cũng thuận_tiện resort mới nên rất sạch_sẽ
bãi biển tuyệt đẹp và sạch_sẽ
nên thay_đổi
ghế nằm ở hồ bơi hơi ít và thường_xuyên full
hàng ngày nên có trái_cây chào buổi sáng thì tuyệt hơn rất nhiều
nhân_viên rất thân thiện
mọi thứ đều tuyệt_vời chắc chắn sẽ quay lại khi có dịp đến Phú Quốc rất tốt

@2019 - SENTIMENT RESEARCH TEAM

Bài giảng KHAI PHÁ DỮ LIỆU WEB - Nguyễn Thành Thủy, MIS Dept. - DUE

Source: Đề tài NCKH Sinh viên 2019, Sentiment Research Team.

11/38

3.1 TỔNG QUAN VỀ XỬ LÝ NGÔN NGỮ TỰ NHIÊN - NLP

❑ Các bài toán cơ bản trong NLP



Bài báo khoa học:

“Vietnamese Sentiment Analysis for Hotel Review based on Overfitting Training and Ensemble Learning”, Thuy Nguyen-Thanh, Giang T.C. Tran


Link: https://www.researchgate.net/publication/338158566_Vietnamese_Sentiment_Analysis_for_Hotel_Review_based_on_Overfitting_Training_and_Ensemble_Learning

Bài giảng KHAI PHÁ DỮ LIỆU WEB - Nguyễn Thành Thủy, MIS Dept. - DUE

Source: Đề tài NCKH Sinh viên 2019, Sentiment Research Team.

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

- ❑ Quy trình chuẩn bị dữ liệu để xây dựng mô hình huấn luyện học máy



Đọc thêm:

- <https://blog.vietnamlab.vn/ban-ve-cong-doan-tien-xu-ly-trong-xu-ly-ngon-ngu-tu-nhien/>

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

❑ Quy trình chuẩn bị dữ liệu để xây dựng mô hình huấn luyện học máy

- Chuyển văn bản thành chữ thường;
- Loại bỏ URL;
- Xóa dấu câu;
- Xóa chữ số;
- Tách câu;
- Chuyển biểu tượng cảm xúc thành văn bản (Emojis and Emoticons);
- Xóa các từ không có nghĩa (Stop Words);
- Chuẩn hóa văn bản (Standardizing Text);
- Sửa lỗi chính tả (Correcting Spelling);
- Tách từ (Tokenizing);
- Chuẩn hóa từ (Stemming and Lemmatization);
- Khám phá dữ liệu văn bản (Exploring Text Data);

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

- Chuyển văn bản thành chữ thường:

Ví dụ 3.1: Sử dụng hàm `lower()`

```
text="This is introduction to NLP. It is likely to be  
useful, to people, Machine learning is the new  
electrcity. There would be less hype around AI and more  
action going forward, python is the best tool! R is  
good langauage, I like this book, I want more books  
like this."
```

```
text_pre=text.lower()  
print(text_pre)
```



this is introduction to nlp. it
is likely to be useful, to
people, machine learning is
the new electrcity. there
would be less hype around
ai and more action going
forward, python is the best
tool! r is good langauage, i
like this book, i want more
books like this.

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

- Xóa dấu câu:

Ví dụ 3.2a: Sử dụng thư viện re

```
text="This is introduction to NLP. It is likely to be  
useful, to people, Machine learning is the new  
electrcity. There would be less hype around AI and more  
action going forward, python is the best tool! R is  
good langauage, I like this book, I want more books  
like this."
```

#Cach 1: Su dung thu vien re

```
text_pre=re.sub(r'^\w\s','',text)  
print(text_pre)
```



This is introduction to NLP It
is likely to be useful to
people Machine learning is
the new electrcity There
would be less hype around
AI and more action going
forwardpython is the best
tool R is good langauage I
like this book I want more
books like this

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

- Xóa dấu câu:

Ví dụ 3.2b: Sử dụng thư viện **string**

```
text="This is introduction to NLP. It is likely to be  
useful, to people, Machine learning is the new  
electrcity. There would be less hype around AI and  
more action going forward, python is the best tool! R  
is good langauge, I like this book, I want more books  
like this."
```

```
#Cach 2: Su dung thu vien string
```

```
for c in string.punctuation:  
    text= text.replace(c, '')
```

```
text_pre=text
```

```
print(text_pre)
```



This is introduction to NLP It
is likely to be useful to
people Machine learning is
the new electrcity There
would be less hype around
AI and more action going
forwardpython is the best
tool R is good langauge I
like this book I want more
books like this

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

▪ Xóa chữ số:

Ví dụ 3.2c: Sử dụng thư viện re

```
import re

text="Tại Đại hội Thể thao Đông Nam Á 2021, Đội tuyển nữ Việt Nam và Đội tuyển U-23 Việt Nam đã bảo vệ thành công tấm huy chương vàng tại SEA Games 30 sau chiến thắng lần lượt trước Đội tuyển nữ Thái Lan (1-0) và Đội tuyển U-23 Thái Lan (1-0)."
```

```
text_pre = re.sub("\d+", " ", text)
print(text_pre)
```

Tại Đại hội Thể thao Đông Nam Á , Đội tuyển nữ Việt Nam và Đội tuyển U- Việt Nam đã bảo vệ thành công tấm huy chương vàng tại SEA Games sau chiến thắng lần lượt trước Đội tuyển nữ Thái Lan (-) và Đội tuyển U- Thái Lan (-).

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

- Xóa thẻ HTML:

Ví dụ 3.2d: Sử dụng thư viện BeautifulSoup

```
from bs4 import BeautifulSoup
Text = "<html><head><title>Khoa học dữ  
liệu</title><style>.call {background-color:black;}  
</style><script>getit</script></head><body>Là một ngành  
học<div>đáp ứng xu hướng việc làm trong tương  
lai.</div></body></html>"

def remove_tags(html):
    # parse html content
    soup = BeautifulSoup(html, "html.parser")
    for data in soup(['style', 'script']):
        data.decompose() # Remove tags
    return ' '.join(soup.stripped_strings)

print(remove_tags(Text))
```



Khoa học dữ liệu Là một ngành học đáp ứng xu hướng việc làm trong tương lai.

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

- Chuyển đổi biểu tượng cảm xúc thành văn bản:
 - Sử dụng thư viện **emot**

Emoji Icons

-  → `smiling_face_with_heart-eyes`
-  → `zany_face`
-  → `nerd_face`

Emoji Unicode

- `:D` → `Laughing_big_grin_or_laugh_with_glasses`
- `;)` → `Wink_or_smirk`

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

- Chuyển đổi biểu tượng cảm xúc thành văn bản:

Ví dụ 3.3: Sử dụng thư viện emot

```
def converting_emojis(text):  
    for x in EMOTICONS_EMO:  
        text = text.replace(x, "_".join(EMOTICONS_EMO[x].replace(",", "").replace(":", "").split()))  
  
    for x in UNICODE_EMOJI:  
        text = text.replace(x, "_".join(UNICODE_EMOJI[x].replace(",", "").replace(":", "").split()))  
  
    return text  
  
text = "What are you saying 😊. I am the boss :), and why are you so 😞"  
text_pre=converting_emojis(text)  
print(text_pre)
```

What are you saying **face_with_tears_of_joy**. I am the boss **Happy_face_or_smiley**, and why are you so **unamused_face**

Đọc thêm: https://github.com/NeelShah18/emot/blob/master/emot/emo_unicode.py

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

▪ Xóa các từ không có nghĩa (Stop Words):

- Stop Words là từ có tần suất xuất hiện lớn trong văn bản, thường không mang ý nghĩa quan trọng;
 - Ví dụ: giới từ, liên từ, đại từ,...
 - "the", "and", "a", "an", "in",...
 - "ai", "bạn", "có", "biết",...
- Loại bỏ Stop Words nhằm giảm kích thước của văn bản, tăng tốc độ xử lý và cải thiện độ chính xác;
- Stop Words cũng có thể mang ý nghĩa, việc loại bỏ Stop Words có thể làm giảm chất lượng dữ liệu.
- Có 3 cách để loại bỏ Stop Words: Thư viện xử lý NNTN, dùng từ điển, dựa theo tần suất xuất hiện của từ;

Tham khảo bộ Stop Words tiếng Việt, tác giả Van-Duyet Le:

<https://github.com/stopwords/vietnamese-stopwords/blob/master/vietnamese-stopwords.txt>

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

- Xóa các từ không có nghĩa (Stop Words):

Ví dụ 3.4a: Sử dụng thư viện nltk

```
text="This is introduction to NLP. It is likely to be useful, to people, Machine learning is the new electrcity. There would be less hype around AI and more action going forward, python is the best tool! R is good langauage, I like this book, I want more books like this."
```

```
#remove stop words
```

```
stop = stopwords.words('english')
```

```
text_pre = " ".join(text for text in text.split() if text not in stop)
```

```
print(text_pre)
```

This introduction NLP. It likely useful, people, Machine learning new electrcity. There would less hype around AI action going forward,python best tool! R good langauage, I like book, I want books like this.

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

- Xóa các từ không có nghĩa (Stop Words):

Ví dụ 3.4b: Sử dụng từ điển Stop Words

```
text="Theo giới chuyên môn, lối chơi của U20 Việt Nam khá đa dạng, linh hoạt hơn trong  
sơ đồ đội hình và chiến thuật, có khả năng chuyển tình thế nhanh trong tấn công và  
phòng ngự."
```

```
path=os.path.dirname(__file__)  
f = open(path+r"\vietnamese-stopwords.txt", "r", encoding="utf-8")  
#Get Stop words Dictionaries  
List_StopWords=f.read().split("\n")  
  
#remove stop words  
text_pre=" ".join(text for text in text.split() if text not in List_StopWords)  
print(text_pre)
```



Theo giới chuyên môn, lối U20 Việt Nam đa dạng, linh hoạt sơ đồ đội hình chiến thuật, khả năng tình công phòng ngự.

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

▪ Tách câu:

- Sử dụng đặc trưng của dấu chấm để tách câu;
- Sử dụng thư viện xử lý NNTN.

Ví dụ 3.5a: Sử dụng dấu chấm câu

```
text="U20 Qatar vẫn còn cơ hội đi tiếp dù khá mong manh. Họ phải thắng Úc đậm và đợi chờ U20 Việt Nam đánh bại Iran. Khi đó, Qatar mới có thể nghĩ đến chuyện đoạt vé vào vòng trong. Đó là cơ sở để U20 Việt Nam kỳ vọng vào tấm vé đi tiếp ngay cả khi không thể có kết quả tốt trước Iran."
```

```
text_pre=text.split(".")
text_pre.remove("")
print(text_pre)
```

```
['U20 Qatar vẫn còn cơ hội đi tiếp dù khá mong manh', ' Họ phải thắng Úc đậm và đợi chờ U20 Việt Nam đánh bại Iran', ' Khi đó, Qatar mới có thể nghĩ đến chuyện đoạt vé vào vòng trong', ' Đó là cơ sở để U20 Việt Nam kỳ vọng vào tấm vé đi tiếp ngay cả khi không thể có kết quả tốt trước Iran']
```

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

▪ Tách câu:

- Sử dụng đặc trưng của dấu chấm để tách câu;
- Sử dụng thư viện xử lý NNTN.

Ví dụ 3.5b: Sử dụng thư viện **nltk**

```
import nltk
text="U20 Qatar vẫn còn cơ hội đi tiếp dù khá mong manh. Họ phải thắng Úc đậm và đợi chờ U20 Việt Nam đánh bại Iran. Khi đó, Qatar mới có thể nghĩ đến chuyện đoạt vé vào vòng trong. Đó là cơ sở để U20 Việt Nam kỳ vọng vào tấm vé đi tiếp ngay cả khi không thể có kết quả tốt trước Iran."

sentence_list = nltk.sent_tokenize(text)
print(sentence_list)
```

['U20 Qatar vẫn còn cơ hội đi tiếp dù khá mong manh.', 'Họ phải thắng Úc đậm và đợi chờ U20 Việt Nam đánh bại Iran.', 'Khi đó, Qatar mới có thể nghĩ đến chuyện đoạt vé vào vòng trong.', 'Đó là cơ sở để U20 Việt Nam kỳ vọng vào tấm vé đi tiếp ngay cả khi không thể có kết quả tốt trước Iran.']

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

▪ Chuẩn hóa văn bản (Standardizing Text):

- Là quá trình chuyển đổi văn bản về một dạng chuẩn;
- Bao gồm loại bỏ các ký tự số, thay thế các từ viết tắt bằng các từ đầy đủ tương ứng, ...

Ví dụ:

NCKH → Nghiên cứu khoa học
NNTN → Ngôn ngữ tự nhiên
XHCN → Xã hội chủ nghĩa

Nguồn từ điển viết tắt, tiếng lóng trong tiếng Việt:

- <https://gist.github.com/nguyenvanhieuvn/7d9441c10b3c2739499fc5a4d9ea06fb>

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

- Chuẩn hóa văn bản (Standardizing Text):

Ví dụ 3.6: Sử dụng từ điển các từ viết tắt

```
lookup_dict = {'nlp':'natural language processing', 'ur':'your', "wbu" : "what about you"}

def text_std(input_text):
    words = input_text.split()
    # Get Abbreviations Words
    text_pre=""
    for word in words:
        w=word
        w = re.sub(r'^\w\s',' ',w) #Removing Punctuation
        if w.lower() in lookup_dict:
            word=lookup_dict[w]
        text_pre=text_pre + " " + word
    return text_pre

text_pre=text_std("I like nlp it's ur choice.")
print(text_pre)
```

I like natural language processing it's your choice.

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

▪ Sửa lỗi chính tả (Correcting Spelling):

Ví dụ 3.7a: Sử dụng TextBlob

```
from textblob import TextBlob
text="GFG is a good compny and alays value ttheir employees."

text_pre=TextBlob(text).correct()
print(text_pre)
```

```
from autocorrect import spell
text="GFG is a good compny and alays value ttheir employees."

text_pre=spell(text)
print(text_pre)
```



GFG is a good company and always value their employees.

Đọc thêm:

- <http://norvig.com/spell-correct.html>
- <https://viblo.asia/p/thu-ap-dung-mo-hinh-dich-may-vao-bai-toan-tu-dong-sua-loi-tieng-viet-maGK7vJB5j2>

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

▪ Tách từ (Tokenizing):

- Ví dụ 3.8a: Sử dụng thư viện nltk

```
import nltk
```

```
text="This is introduction to NLP. It is likely to be  
useful, to people, Machine learning is the new  
electrcity. There would be less hype around AI and more  
action going forward,python is the best tool! R is good  
langauage, I like this book, I want more books like  
this."
```

```
text_pre=nltk.word_tokenize(text)
```

```
print(text_pre)
```

```
['This', 'is', 'introduction', 'to', 'NLP',  
, '.', 'It', 'is', 'likely', 'to', 'be', 'useful',  
, ', ', 'to', 'people', ', ', 'Machine',  
, 'learning', 'is', 'the', 'new',  
, 'electrcity', ', ', 'There', 'would', 'be',  
, 'less', 'hype', 'around', 'AI', 'and',  
, 'more', 'action', 'going', 'forward', ', ',  
, 'python', 'is', 'the', 'best', 'tool', '!',  
, 'R', 'is', 'good', 'langauage', ', ', 'I',  
, 'like', 'this', 'book', ', ', 'I', 'want',  
, 'more', 'books', 'like', 'this', ', '.]
```

Đọc thêm:

- <https://vinbigdata.com/tokenization-la-gi-cac-ky-thuat-tach-tu-trong-xu-ly-ngon-ngu-tu-nhien/>
- https://github.com/undertheseanlp/word_tokenize

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

- Tách từ (Tokenizing):
 - Ví dụ 3.8b: Sử dụng thư viện **Underthesea** cho tiếng Việt

```
from underthesea import word_tokenize

text="U20 Việt Nam kỳ vọng vào tấm vé đi tiếp ngay cả  
khi không thể có kết quả tốt trước Iran"
text_pre= word_tokenize(text, format="text")
print(text_pre)
```



U20 Việt_Nam kỳ_vọng vào tấm vé
đi tiếp ngay cả khi không_thể có
kết_quả tốt trước Iran

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

▪ Chuẩn hóa từ (Stemming and Lemmatization):

- Stemming và Lemmatization là hai kỹ thuật để giảm thiểu sự đa dạng của các từ trong văn bản. Được sử dụng để giảm kích thước của bộ từ vựng trong các tác vụ NLP;

- **Stemming** là quá trình chuyển từ về dạng cơ bản, bằng cách loại bỏ các hậu tố để giữ lại cơ bản của từ đó;

- Ví dụ: jumping → jump
 caring → car

- **Lemmatization** sử dụng thông tin ngữ pháp và văn phong để đưa từ về dạng nguyên thể.

- Ví dụ: am, are, is → be
 car, cars, car's, cars' → car

the boy's cars are different colors
→ the boy car be differ color

Đọc thêm:

- <https://nlp.stanford.edu/IR-book/html/htmledition/stemming-and-lemmatization-1.html>
- <https://www.datacamp.com/tutorial/stemming-lemmatization-python>

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

- Chuẩn hóa từ (Stemming and Lemmatization):

Ví dụ 3.9: sử dụng thư viện nltk

```
text = "I have three visions for India. In 3000 years of our history, people from all  
over the world have come and invaded us, captured our lands, conquered our minds."  
#Tokenization (step before stemming)  
sentences = nltk.sent_tokenize(text)  
  
# Lemmatization  
lemmatizer = WordNetLemmatizer()  
  
for i in range(len(sentences)):  
    words = nltk.word_tokenize(sentences[i])  
    words = [lemmatizer.lemmatize(word) for word in words  
              (if word not in set(stopwords.words('english')))]  
    sentences[i] = ' '.join(words)  
  
print(sentences)
```



```
['I three vision India .', 'In 3000 year history , people world come invaded u , captured land , conquered mind .']
```

3.2 TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN – BÀI TẬP

❑ Viết code Python thực hiện các yêu cầu:

- Lấy dữ liệu từ nguồn <https://cnn.com/business>
- Tự động bóc tách tin tức, lưu mỗi tin vào 1 file .txt (vd: 1.txt, 2.txt, ...)
- Tiền xử lý cho các file .txt trên, mỗi file kết quả lưu vào file (vd: 1x.txt, 2x.txt,...);
- Các nội dung tiền xử lý:
 - Chuyển văn bản thành chữ thường;
 - Loại bỏ URL;
 - Xóa dấu câu;
 - Xóa chữ số;
 - Tách câu;
 - Chuyển biểu tượng cảm xúc thành văn bản (Emojis and Emoticons);
 - Xóa các từ không có nghĩa (Stop Words);
 - Chuẩn hóa văn bản (Standardizing Text);
 - Sửa lỗi chính tả (Correcting Spelling);
 - Tách từ (Tokenizing);

3.3 KHÁM PHÁ DỮ LIỆU VĂN BẢN

□ Tổng quan

- Khám phá dữ liệu văn bản: là quá trình tìm hiểu và khám phá các đặc trưng và tính chất của dữ liệu văn bản;
- Giúp chúng ta hiểu rõ hơn về nội dung của tập dữ liệu và có thể phát hiện ra những đặc trưng quan trọng, giúp cải thiện các tác vụ xử lý NLP;
- Các công việc thường được thực hiện trong quá trình khám phá dữ liệu văn bản bao gồm:
 - Thống kê tần suất xuất hiện của từ và cụm từ;
 - Phân tích từ vựng;
 - Phân tích cú pháp;
 - Phân tích ngữ cảnh;
 - Khám phá các mối liên hệ.

3.3 KHÁM PHÁ DỮ LIỆU VĂN BẢN

❑ Cài đặt trên Python

■ Ví dụ 3.10: Sử dụng thư viện nltk

(Nguồn dữ liệu: <https://www.deeplearning.ai/resources/natural-language-processing/>)

- Thống kê tần suất xuất hiện của các từ trong bộ dữ liệu (sau khi xóa stopwords)

Introduction

Natural Language Processing (NLP) is one of the hottest areas of artificial intelligence (AI) thanks to applications like text generators that compose coherent essays, chatbots that fool people into thinking they're sentient, and text-to-image programs that produce photorealistic images of anything you can describe. Recent years have brought a [revolution](#) in the ability of computers to understand human languages, programming languages, and even biological and chemical sequences, such as DNA and protein structures, that resemble language. The latest AI models are unlocking these areas to analyze the meanings of input text and generate meaningful, expressive output.

What is Natural Language Processing (NLP)

[Natural language processing \(NLP\)](#) is the discipline of building machines that can manipulate human language — or data that resembles human language — in the way that it is written, spoken, and organized. It evolved from computational linguistics, which uses computer science to understand the principles of language, but rather than developing theoretical frameworks, NLP is an engineering discipline that seeks to build technology to accomplish useful tasks. NLP can be divided into two overlapping subfields: natural language understanding (NLU), which focuses on semantic analysis or determining the intended meaning of text, and natural language

[('nlp', 64), ('models', 55), ('language', 52), ('text', 48), ('word', 45), ('model', 31), ('words', 29), ('learning', 26), ('like', 24), ('input', 24), ('natural', 23), ('used', 23), ('output', 18), ('many', 17), ('using', 17), ('deep', 17), ('document', 17), ('one', 16), ('data', 16), ('processing', 15), ('classification', 15), ('probability', 15), ('also', 15), ('techniques', 15), ('sentence', 14), ('ai', 13), ('tasks', 13), ('use', 13), ('neural', 13), ('based', 12), ('information', 12), ('libraries', 12), ('features', 11), ('example', 11), ('task', 11), ('topic', 11), ('training', 11), ('google', 10), ('systems', 10), ('languages', 9), ('machine', 9), ('sentiment', 9), ('documents', 9), ('modeling', 9), ('markov', 9), ('hidden', 9), ('applications', 8), ('human', 8), ('two', 8), ('analysis', 8)]

BÀI TẬP ÔN TẬP

Câu 1. (Làm cá nhân)

a. Thu thập dữ liệu văn bản trang web và lưu về file Cau1.txt

Nguồn: https://en.wikipedia.org/wiki/Artificial_intelligence

b. Thực hiện tiền xử lý nội dung của file Cau1.txt, lưu kết quả vào file Cau1_txl.txt;

c. Thống kê tần suất từ xuất hiện trong văn bản;

d. Trực quan hóa bằng đồ thị và word cloud;

Câu 2. (Làm nhóm)

Sử dụng bộ dữ liệu đã thu thập tại Câu 5, bài tập Slide 50 – Chương 2, để thực hiện các yêu cầu sau:

a. Thực hiện tiền xử lý toàn bộ nội dung các file *.txt;

b. Thống kê tần suất từ xuất hiện trong văn bản;

c. Trực quan hóa bằng đồ thị và word cloud;

Lưu ý: bộ dữ liệu này là văn bản tiếng Việt, nên cần sử dụng các thư viện NLP phù hợp.

Gợi ý, các thư viện hỗ trợ xử lý NNTN tiếng Việt: [Underthesea](#), [pyvi](#), [vntokenizer](#)